PROFESSIONAL PORTFOLIO · PORTAFOLIO PROFESIONAL

Lázaro Gómez Ontiveros

Choose your language · Elige tu idioma

ENGLISH

Read in English →

21 pages · starts on page 2 of this file

ESPAÑOL

Leer en español →

21 páginas · comienza en la página 23 de este archivo

Click a button to jump to that version, or use the bookmarks panel of your PDF reader.
Haz clic en un botón para ir a esa versión, o usa el panel de marcadores de tu lector de PDF.

All data, figures and scenarios are synthetic and built to illustrate method. · Todos los datos, cifras y escenarios son sintéticos y fueron construidos para ilustrar el método.

PROFESSIONAL PORTFOLIO

Lázaro Gómez Ontiveros

Data-driven service operations
Method, models, governance and applied AI cases

Chief Operations Officer · Technology services

Multi-country operations in LATAM · Telecommunications and managed services

Mexico City · lazarogomez@hotmail.com · +52 55 7980 3050

This document presents methods and frameworks developed throughout my career. All data, figures and scenarios are synthetic and were built to illustrate the method. It contains no information from any client, vendor or employer.

HOW TO READ THIS DOCUMENT

Eight pieces, one method

This portfolio does not showcase projects: it shows how I approach an operational problem. Each piece starts from a business question, applies an explicit method and ends in an artifact someone can use the next day. Pieces 7 and 8 take the same method into two complete data and artificial intelligence scenarios, with platforms, CAPEX and OPEX.

> *I turn service operations managed by perception into operations managed by data, without adding headcount.*

Contents

#	Piece	Question it answers	Page
1	Coverage sizing with hourly data	How many people do I need, at what hours, and can I extend service without hiring?	3
2	Operational level agreement framework	If I outsource the operation, how do I keep control and accountability?	5
3	Cooperation model between presales, engineering and operations	How do I avoid selling what operations cannot sustain?	7
4	Executive operations dashboard	What should leadership look at every month, and what not?	9
5	Service and deliverables matrix per contract	How does a commercial catalog become verifiable obligations?	11
6	Commercial intelligence on operational data	What should I offer each client, current or new, without committing what operations cannot sustain?	13
7	**Patient 360: data and AI in a private hospital** NEW	How do I anticipate what each patient needs, and what does it cost to build and run?	16
8	**Predictive operations in retail** NEW	How do I see a failure or a deviation before it hits sales, and what does it cost?	18
—	How I work	The method behind the eight pieces	20

Career at a glance

EXPERIENCE
20+
years in operations and technology

TELECOMMUNICATIONS
21
years in network operations and service delivery

SCOPE
LATAM
multi-country, multi-site operations

EDUCATION
MBA
ITAM (in progress) · B.Eng. Electronics, IPN · Certified Chief AI Officer

A note on the data

Every number in this portfolio is synthetic. The numbers keep the shape and typical behavior of a real operation —the hourly curve, the mix of priorities, the effect of alert bursts, the order of magnitude of a CAPEX— because that is what makes the method understandable, but they do not belong to any real organization. Platform prices are list prices and for reference only. Governance frameworks are presented as generic templates, not as documents from any contract.

01 Coverage sizing with hourly data

From the demand curve to the staffing decision

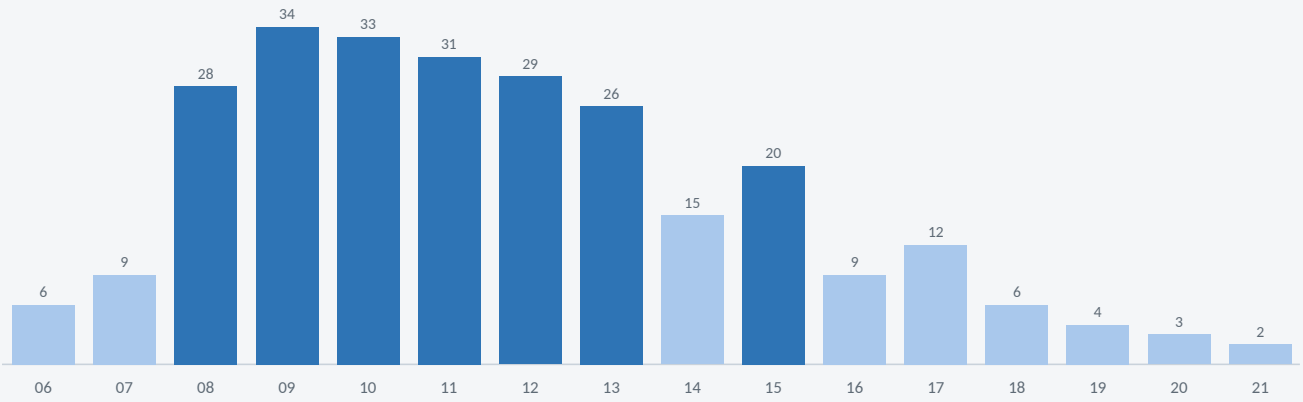
THE PROBLEM

A client asks to extend the service window from 9 to 14 hours a day. The intuitive answer is to hire more people and quote the increase. The right question is a different one: where does demand really sit within the day, and how much capacity is already being wasted in the hours when nothing happens?

THE METHOD

1	2	3	4	5
Extract record-level detail, not the monthly aggregate	Build the hourly demand curve and normalize bursts	Apply handling time and target occupancy	Calculate required resources per time slot with a coverage floor	Design shifts that cover the window with the existing team

STEP 1 · THE DEMAND CURVE (SYNTHETIC DATA, MONTHLY EVENTS BY HOUR)



Two immediate readings. Most demand sits between 08:00 and 13:00, not evenly spread across the day. And the 06:00–07:59 and 17:00–20:59 slots hold 16% of the events that nobody serves today: that is the case for extending the window, and there is no need to assume it.

STEP 2 · SEPARATING REAL DEMAND FROM NOISE

Automatic alerts triggered by a single root event —a link failure, a firmware update— arrive as dozens of records within minutes. If they are not grouped under a parent ticket, they distort three things at once: sizing, compliance measurement and the team's perception of workload. Normalization is the step that changes the result the most, and the one that is almost always skipped.

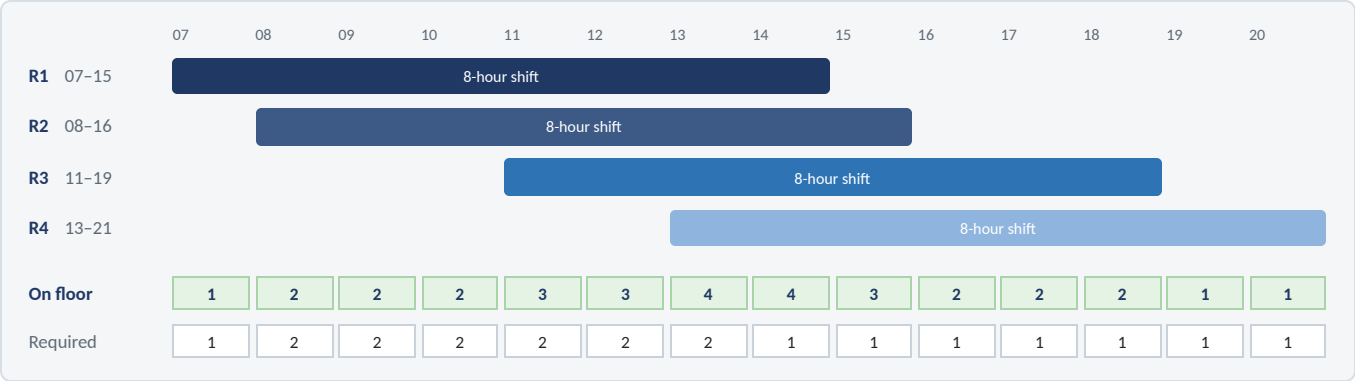
EVENTS IN THE MONTH	AFTER NORMALIZING	DIFFERENCE
338	**281**	**17%**
raw observed volume	real demand attributable to users	monitoring noise, not operational load

STEP 3 · FROM DEMAND TO RESOURCES PER TIME SLOT

The formula is deliberately simple, because it has to hold up in front of a client and in front of finance: resources per slot equal the hour's events divided by working days, times handling time, divided by target occupancy, with a floor of one resource in every hour of the window.

Assumption	Value	Why
Handling time	0.70 h	Observed median, not the mean: the mean gets distorted by long cases
Target occupancy	70%	Leaves 30% for meals, documentation, travel and variability
Working days	21	Monthly base for the period analyzed
Coverage floor	1 resource	Service continuity: no hour of the window is left unattended

STEP 4 · THE SHIFT PROPOSAL



Four staggered 8-hour shifts cover 07:00 to 21:00. The top row is the resulting staff on the floor; the bottom row is the calculated requirement. The mid-afternoon overlap is deliberate: it is the window for shift handover and staggered meals.

THE RESULT

SERVICE WINDOW

9 → 14 h

per working day

HEADCOUNT

No change

same people, redistributed

DEMAND COVERED

84 → 94%

+10 coverage points

The finding that changes the conversation

The total requirement of the extended window is 17 resource-hours a day, and the team on the floor provides 32. The problem was never a lack of people: the four people were all in the same time slot while 16% of demand happened outside of it. Extending hours was not a cost, it was a redistribution.

WHAT I WOULD DO DIFFERENTLY

I would measure actual touch time from the start instead of using median clock time. It is the only assumption with material weight on the result: if real touch time were double, the peak would rise to three resources and the conclusion would change. An honest model declares its fragile assumption.

02 Operational level agreement framework

What to sign when a third party runs the operation

THE PROBLEM

A company transfers its operation to a vendor and keeps contractual accountability toward its client. From that moment on, it answers for a service it does not run. Most agreements signed in this situation cover response times and little more, and leave out exactly what hurts later.

THE PRINCIPLE BEHIND THE WHOLE FRAMEWORK

> *The vendor's commitment must be stricter than the one the company signed with its client. The difference is the management margin.*

If both levels are identical, any vendor deviation immediately becomes a breach toward the client, with no room to validate, escalate or communicate. The practical rule: the internal target equals 80% of the contracted time, with an absolute margin floor for critical priority.

Item	Committed to client	Vendor target	Management margin
P1 resolution	4 h	3 h	1 h
P2 resolution	6 h	4 h 30 min	1 h 30 min
P3 resolution	8 h	6 h	2 h
Monthly availability	99.0%	99.5%	0.5 points

THE FIVE CHAPTERS ALMOST NOBODY INCLUDES

Chapter	What it prevents
Volume bands and demand management	That every load variation gets renegotiated without a rule. Defines base volume, tolerance band and marginal price outside the band.
Vendor operational continuity	That the agreement demands continuity of the client's service and says nothing about the operator's own platforms. Requires a plan, recovery times and an annual test.
Labor compliance and subcontracting	Joint liability when there is staff on the client's site. Periodic evidence and prior authorization of subcontractors.
Step-in right and assisted exit	That the highest level of consequences is a threat without a mechanism. Defines temporary step-in, causes and an exit fee agreed from the start.
Return of operational data	The silent loss of engineering capability: if the vendor operates, the vendor learns. Requires monthly record-level delivery in a usable format.

THE DELIVERABLES MATRIX, IN BOTH DIRECTIONS

An agreement that only lists the vendor's obligations is incomplete: half of all breaches originate in dependencies the contracting party did not deliver on time.

From vendor to contracting party

Deliverable	Frequency
Operations and compliance report	Monthly
Record-level data extract	Monthly
Root cause report	Per event
Reconciled inventory and configuration	Quarterly
Staffing and certifications status	Quarterly
Security incident notification	24 h / 72 h

From contracting party to vendor

Deliverable	Timing
Approved service design package	Before go-live
Tested runbooks	Before go-live
Access and credentials	Before go-live
Monitoring requirements and thresholds	Before go-live
Third-level support	On demand
Notice of scope change	30 to 60 days

RELIEF FOR AN UNMET DEPENDENCY

Exclusions do not work on their own. For the vendor to be relieved from the time count because of someone else's dependency, it must give notice within a defined period; without timely notice, the time counts against it. This is the clause that keeps blame from appearing for the first time at the monthly close, when it can no longer be verified.

ESCALATING CONSEQUENCES, IN BOTH DIRECTIONS

Level	Trigger	Consequence
1	One month below target	Documented action plan, with an owner and a date
2	Two consecutive months	Formal remediation plan with biweekly review
3	Three months or a passed-through penalty	Financial scheme and scope review
4	Repeated breach or serious failure	Step-in right and continuity assessment

And in the other direction: credit recovery after three months of sustained recovery, performance bonuses and shared savings from automation proposed by the vendor. An agreement that only punishes produces a vendor that argues about classifications instead of solving.

WHAT I WOULD DO DIFFERENTLY

I would negotiate the assisted exit fee at the beginning of the agreement, not at the end. It is the only moment when both parties have an incentive to be reasonable, and it is exactly the clause nobody wants to discuss when the relationship is just starting.

03 Cooperation between presales, engineering and operations

How to avoid selling what operations cannot sustain

THE PROBLEM

In many service organizations, the commercial design is done by presales and operations inherits the commitment. Presales optimizes to win; the cost of the mistake is paid by engineering, operations and the margin. The solution is not to put engineering into every opportunity —that turns it into a bottleneck— but to separate two things that today share the same name.

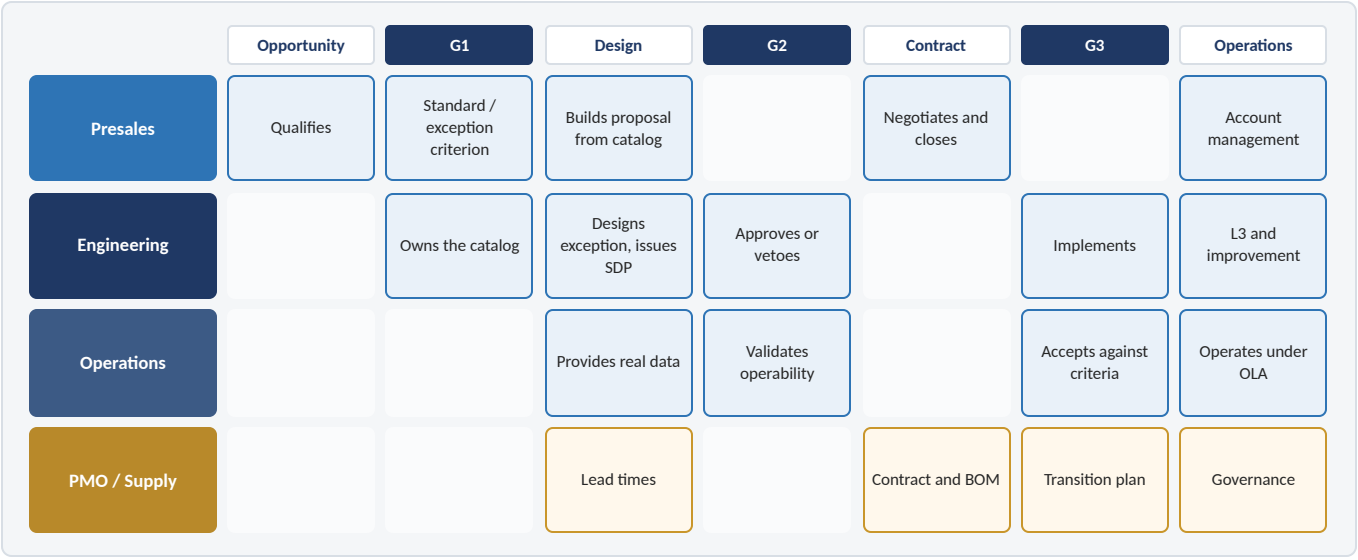
Solution design

What is sold to the client: topology, brands, scope, value proposition. A commercial activity, sensitive to time. It belongs to presales.

Service design

How the service is run and sustained for 24 to 36 months: levels, sizing, costs, profiles, tools, runbooks, acceptance and exit criteria. Governed by engineering.

THE FLOW WITH THREE GATES



Gate	What it decides	Who approves
G1 · Qualification	Whether the opportunity is standard or an exception. Off-catalog, new brand, different level or a service never operated goes to design.	Presales, with criteria defined by engineering
G2 · Operability	Whether operations can sustain what is about to be committed, at the proposed level and cost. Requires a joint signature.	Operations, with engineering review
G3 · Transition	Whether the service can go into production: tested runbooks, active monitoring, reconciled inventory, trained staff.	Operations accepts against criteria

THE MECHANISM THAT AVOIDS THE BOTTLENECK

If engineering reviewed every opportunity, no proposal would go out on time. The way out is to pre-design: a catalog of already approved service patterns —base level, capacity model, unit cost, profiles, tools, standard runbook— from which presales builds quotes by assembling blocks. The goal is for 80% of opportunities not to require an engineering cycle.

STANDARD PATH
80%
of opportunities solved from the catalog

PROPOSAL CYCLE
< 6 days
sustainable target with a published catalog

EXCEPTIONS
→ catalog
each exception sold once is industrialized

RESPONSIBILITY MATRIX

A: single approver · R: executes · C: consulted · I: informed

Activity	Presales	Architecture	Engineering	Operations	PMO
Opportunity qualification	A/R	C	I	I	I
Commercial proposal	A/R	C	I	I	C
Catalog and design standards	I	A	R	C	I
Service design package	C	A	R	C	I
Sizing and capacity	I	A	R	C	C
Operability validation	I	C	R	A	I
Final costing and lead times	C	I	C	I	A/R
Technical approval before signing	I	A/R	C	C	C
Implementation and transition	I	C	A/R	C	R
Operation under agreed levels	I	I	A	R	C
Design improvement	I	A	R	R	I

The two assignments that are always debated

In operability validation the approver is operations, not engineering: whoever is going to operate must be able to say no. Engineering keeps its own brake in the technical approval before signing. They are two different controls and neither replaces the other.

In daily operations, execution belongs to the vendor or operations, but accountability stays with delivery engineering, because the company answers to the client even when it does not execute.

WHAT I WOULD DO DIFFERENTLY

I would publish the catalog before activating the gates. If the governance model goes live without a catalog, every opportunity becomes an exception and engineering becomes exactly the bottleneck the design was meant to avoid. The order matters more than the design.

04 Executive operations dashboard

Seven indicators, three questions, one page

THE PROBLEM

Operational dashboards fail from excess, not from lack. Forty indicators on one screen produce the same paralysis as none. The discipline is to choose the smallest set that lets leadership answer three questions and decide.

Are we delivering?
Health of the committed service. If this fails, everything else is irrelevant.

Are we making money?
Real profitability of delivery, not the one projected at signing.

Can we sustain it?
Capacity, talent and future demand. The pillar nobody looks at until it breaks.

THE SEVEN INDICATORS

Pillar	Indicator	Why this one and not another
Service	Compliance with agreed levels	It is the contractual commitment: it defines whether there is a penalty
Service	First contact resolution	The only indicator that improves cost and experience at the same time
Service	Incident recurrence	Separates structural improvement from efficient firefighting
Finance	Real margin per contract	Against the designed margin: the deviation reveals the problem before the income statement does
Finance	Days sales outstanding	The service can be profitable while the account keeps destroying cash
Sustainability	Capacity utilization	Below 65% there is slack; above 85% it breaks
Sustainability	Team turnover	The most honest indicator of whether the operating model is sustainable

The design principle

Every indicator must be able to drill down to the evidence that produced it: from the percentage to the contract, from the contract to the ticket. A number that cannot be traced gets debated in the committee instead of being decided on. Traceability is not a dashboard feature, it is its condition for existing.

WHAT IT LOOKS LIKE (SYNTHETIC DATA)



THE READING THAT MATTERS

This synthetic dashboard tells a story that a service-only dashboard would hide: compliance improves for six months in a row, but margin deteriorates and turnover rises. It is the classic pattern of an operation buying performance with the team's effort. Service looks good today and will break within two quarters.

Why the sustainability pillar exists

Without it, leadership congratulates the team on the green indicator and finds out about the problem when three key people resign. Turnover and utilization are not HR metrics: they are the leading indicators of next year's service.

WHAT I WOULD DO DIFFERENTLY

I would add an eighth indicator for data quality —records without an assigned owner, closures without a root cause— in the first version, not the second. Every other number depends on it, and when it fails the dashboard is not wrong: it lies with confidence.

05 From commercial catalog to verifiable obligations

The matrix that translates what is sold into what must be delivered

THE PROBLEM

The commercial catalog says what each contract tier includes. Operations needs something else: who executes each service, who is accountable for it and what it delivers, how often and by when. There is usually a gap between those two documents, and that gap is where uncontracted work gets absorbed and margin is lost without anyone recording it.

TIER STRUCTURE (GENERIC FOUR-LEVEL EXAMPLE)

Element	Basic	Extended	Managed	Custom
Service window	8x5	24x7	24x7	Per contract
Mode	Reactive	Reactive	Reactive and managed	Proactive and managed
Monitoring	—	—	Included	Included
Root cause analysis	—	Included	Included	Included
Capacity management	—	—	Included	Per contract
Preventive maintenance	—	—	Included	—
Penalties	Do not apply	Do not apply	Apply	Apply

The observation that usually goes unnoticed

The extended tier has a continuous window with purely reactive service and no monitoring. That means sustaining 24-hour availability with no automatic detection: demand only comes in when the client reports. Its team is sized for coverage, not volume, and it is almost always the least profitable tier in the catalog. Spotting it before signing is the difference between a healthy contract and one you defend for two years.

EXCLUDED SERVICES, DECLARED AS SUCH

What is not included must be written with the same precision as what is. Without an explicit statement, operations ends up absorbing it in practice: on-call coverage for special events, management of the client's vendors, site surveys, work at heights, own stock of spare parts. Each one carries its operational implication, so the commercial conversation is an informed one.

THE COLUMN THAT TURNS A CATALOG INTO AN OPERATIONAL AGREEMENT

It is not the applicability column, but the execution column: who does each thing when the operation is split between the company and a third party.

Service	Practice	Execution and accountability
Service desk	Incidents	Operator executes · company answers to the client
Remote support L1 and L2	Incidents	Operator executes · escalates to own third level
Manufacturer follow-up	Incidents	Own supply manages · operator provides technical evidence
Normal change management	Changes	Operator executes · own engineering authorizes
Monitoring	Events	Vendor operates · thresholds and severities defined by the company
Capacity management	Capacity	Own engineering, with data delivered by the operator
Inventory and configuration	Assets	Operator maintains · the reference record belongs to the company
Continuous improvement	Improvement	Own engineering proposes · operator executes under change control

DELIVERABLES: THE COMMERCIAL ONES AND THE ONES NOBODY WRITES DOWN

Committed to the client

Deliverable	Deadline
On-site event report	24 business h
Root cause analysis	5 business days
Change control	Before executing
Monthly compliance report	Business day 3
Inventory report	Business day 5

Internal, not visible to the client

Deliverable	Frequency
Record-level operations data	Monthly
On-site inventory reconciliation	Quarterly
Staffing and certifications status	Quarterly
Design deviation log	Monthly
Grouped burst log	Monthly

Why the internal deliverables matter more

The commercial ones are reviewed in the committee with the client and nobody forgets them. The internal ones are claimed by no one, and they are precisely the ones that preserve the ability to design: without record-level operational data, the organization loses, within two or three contract cycles, the information it needs to size, quote and improve. It is a silent degradation.

WHAT I WOULD DO DIFFERENTLY

I would set the verification checklist before negotiating the first account, not after the third. Twelve points —confirmed window, distinction between response and resolution, request catalog, thresholds, penalty scheme, declared exclusions— prevent most of the discussions that later get resolved by conceding.

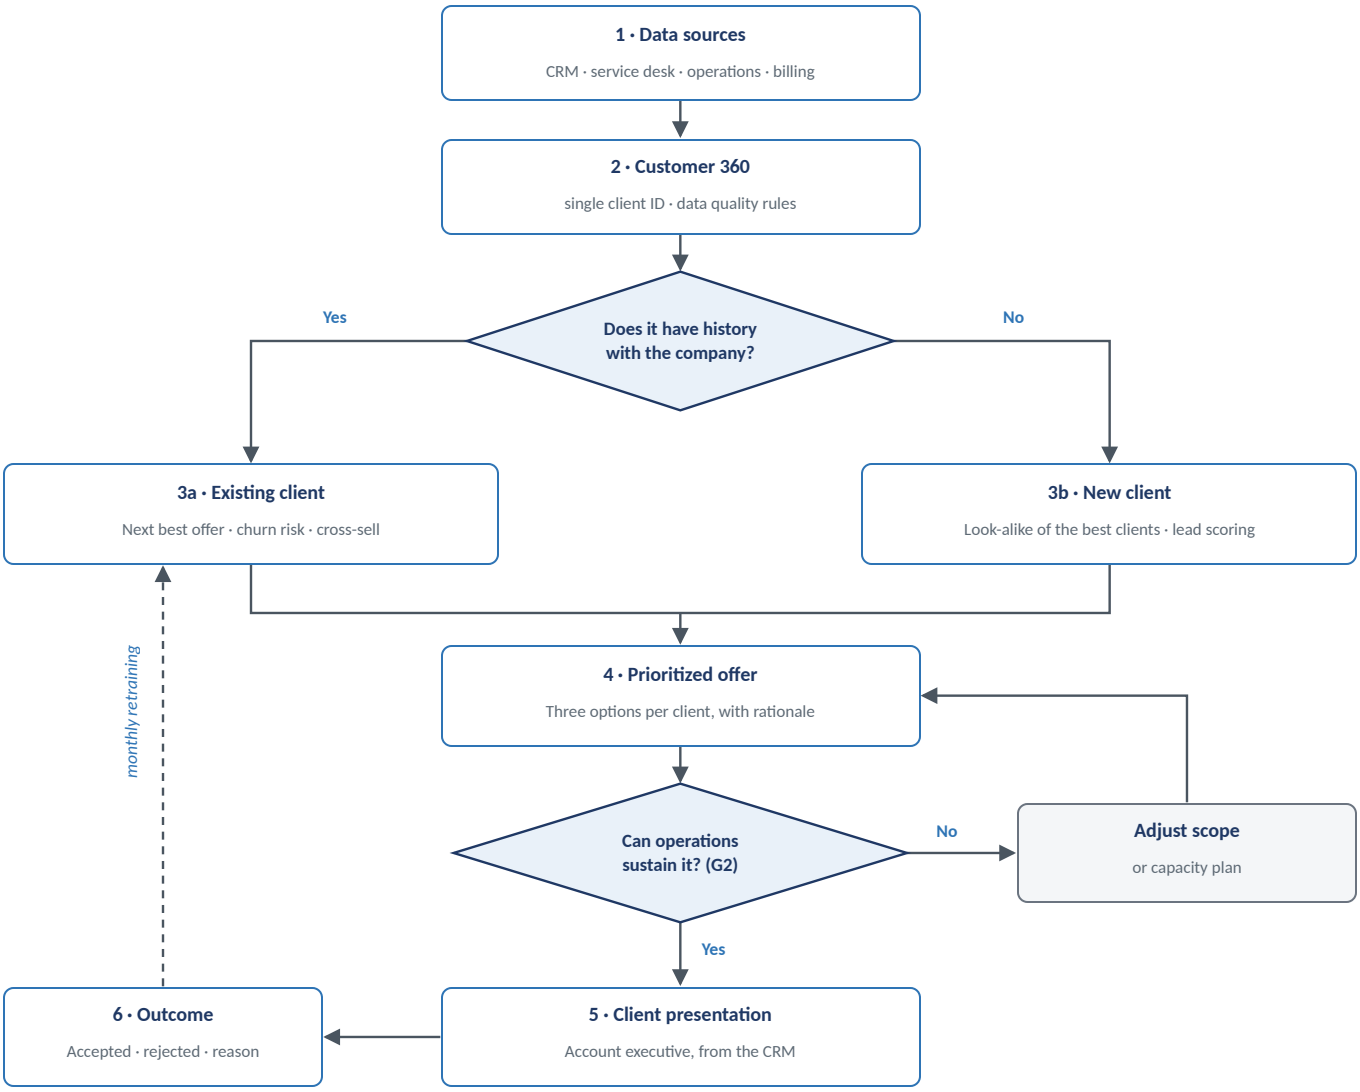
06 Commercial intelligence on operational data

What to offer each client, without selling what operations cannot sustain

THE PROBLEM

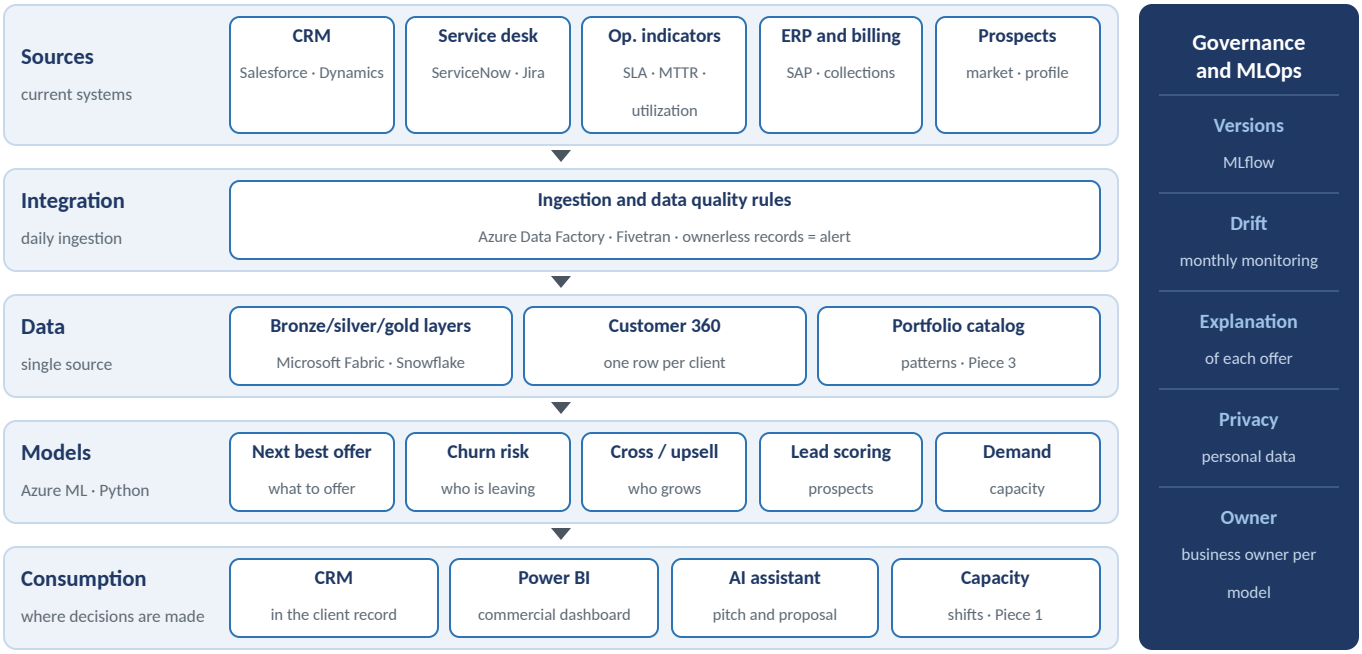
Sales decides what to offer by intuition and quarterly quota; operations knows which client is saturating its capacity, which one lives at the edge of its SLA and which one pays late. That information exists, but it lives in systems that do not talk to each other. The result: everyone gets the same offer, the client who was already sending signals is lost, and what is sold is what nobody can sustain later.

THE FLOW · FROM OPERATIONAL DATA TO THE OFFER



The lower diamond is the same operability gate from Piece 3: no recommendation reaches the client unless operations confirms it can sustain it at the proposed level and cost. Each outcome, accepted or rejected, retrains the model.

THE ARCHITECTURE · FIVE LAYERS AND CROSS-CUTTING GOVERNANCE



The tools are interchangeable examples: the architecture adapts to the ecosystem the company already has. What cannot be replaced is the Customer 360 layer and the governance.

FIVE MODELS, FIVE BUSINESS QUESTIONS

Model	Question	Signals used	Suggested technique
Next best offer	What should I offer this client now?	Purchase history, real service usage, similar clients	Gradient boosting · collaborative filtering
Churn risk	Who will leave if I do nothing?	Missed SLAs, recurrence, days outstanding, tickets	Classification · gradient boosting
Cross-sell and upsell	Who can grow, and toward which tier?	Contracted tier vs. real usage, exceeded capacity	Classification + catalog rules
Lead scoring	Which prospect looks like my best clients?	Industry, size, region, profile of the most profitable clients	Look-alike profiling
Demand forecast	Will I be able to sustain what is about to be sold?	Pipeline, seasonality, hourly demand curve	Time series

Why not a single neural network

With tabular business data —sales, tickets, indicators— gradient boosting models match or beat neural networks with less data, and they can be explained to a sales director. Neural networks are reserved for text: emails and tickets, where the reason for dissatisfaction is not in any structured field.

SYNTHETIC EXAMPLE · FOUR CLIENTS, FOUR DECISIONS

Client	Tier	Operational signal	Churn	Recommendation	Operable?
Client A	Basic 8x5	22% of tickets arrive outside business hours	Low	Extended with a wider window	Yes: shift redistribution, no hiring (Piece 1)
Client B	Managed	SLA 91% and 12% recurrence three months in a row	High	None: retention plan first	Not applicable until service recovers
Client C	Extended	Capacity at 92% for a whole quarter	Medium	Capacity management	Yes, within the catalog
Prospect D	—	Profile similar to the most profitable 10% of the portfolio	—	Managed	Requires operability validation (G2)

Client B is the case that justifies the whole model: without service data, sales would have offered an upgrade to a client who is about to leave.

THE OFFER · OPERATIONAL COMMERCIAL INTELLIGENCE IN THREE PHASES

Phase	Duration	What is delivered	Criterion to move forward
1 · Data diagnostic	4 weeks	Source inventory, single client ID, data quality report, prioritized use cases	80% of clients reconciled across CRM, service and billing
2 · Pilot	8–10 weeks	Churn risk and next best offer for one segment; recommendation visible in the CRM; dashboard	Executives use the recommendation in at least 30% of their accounts
3 · Scale-up	3–6 months	Five models, MLOps, link to capacity planning and a generative AI assistant	Real margin of what is sold equal to or above the designed margin

HOW IT IS MEASURED (ILLUSTRATIVE TARGETS)

CONVERSION
+15%
offers accepted vs. generic offer

RETENTION
−20%
churn in clients flagged at risk

PROPOSAL CYCLE
< 6 d
with pre-built offer and catalog

MARGIN
≥ 0 pp
real vs. designed deviation

THE FRAGILE ASSUMPTION

That the CRM, the service desk and billing share a client identifier. If they do not, the models learn from misattributed records and recommend with confidence on wrong data. That is why the first phase ends in client reconciliation, not in a model: it is the least glamorous work and the one that decides whether everything else is useful.

Where this offer fits

In operations leadership, managed services delivery or digital transformation roles, where operations stops being seen as a cost center and becomes a source of growth: the same data that sustains the SLA decides what to sell, to whom and when.

07 Patient 360: data and AI in a private hospital

Anticipating what each patient needs, and knowing what it costs to build and run

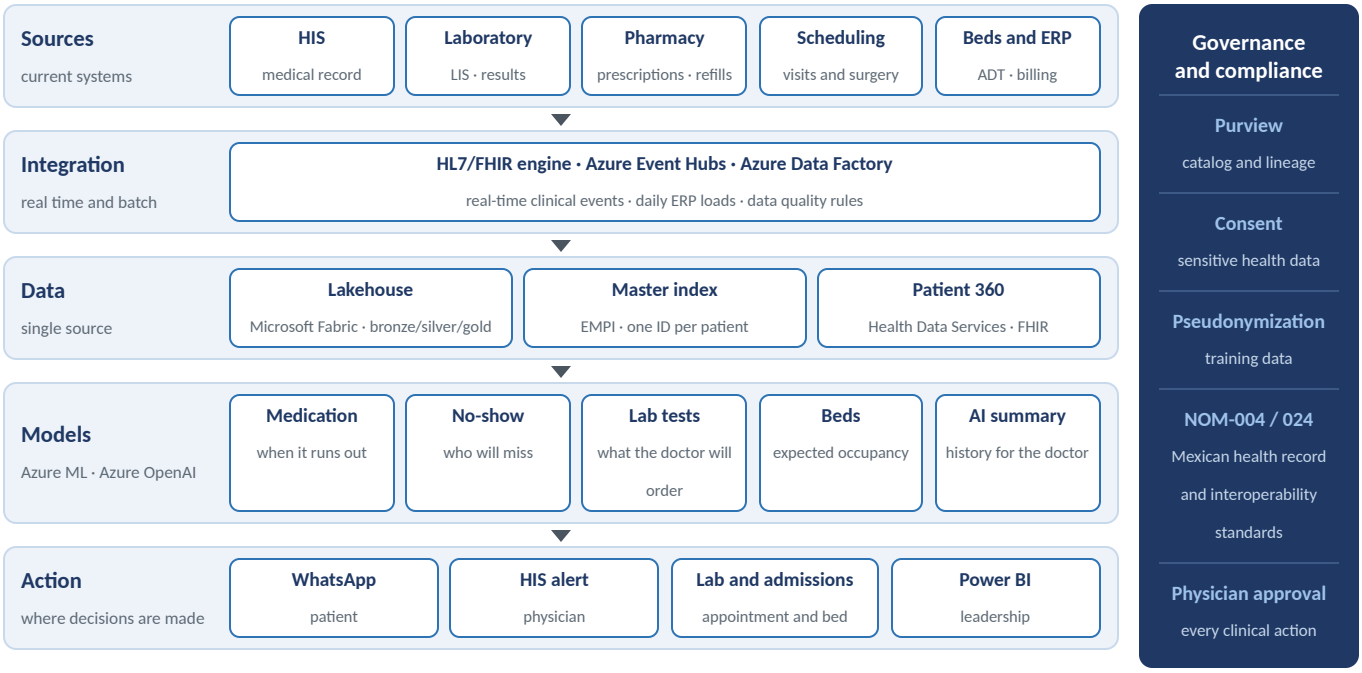
THE PROBLEM

A private hospital has each patient scattered across seven systems that do not talk to each other: medical records, scheduling, pharmacy, laboratory, operating rooms, beds and billing. The cost shows up as missed appointments, interrupted treatments, same-day surgery cancellations and balances discovered at discharge. The question is not which AI model to use, but how to turn seven partial records into one view that acts before the problem.

THE METHOD

1	2	3	4	5
Unify identity: a single patient ID (EMPI)	Build the 360 view on the FHIR standard	Models that anticipate, not that report	Orchestrate actions with physician approval	Measure the baseline and scale in phases

THE ARCHITECTURE · FIVE LAYERS AND CROSS-CUTTING GOVERNANCE



SIX MODELS, SIX BUSINESS QUESTIONS

Model	Question	Suggested technique
Medication depletion	When will it run out, and will the refill happen here?	Rules + adherence regression
No-show	Who is going to miss the appointment?	Classification · gradient boosting
Pre-visit lab tests	Which tests will the doctor order at the visit?	Clinical rules + recommendation
Bed demand	How many beds per day and type?	Time series
Readmission and collections	Which patient or which account is at risk?	Classification and scoring
Pre-visit summary	What does the doctor need to know in 30 seconds?	Generative AI with guardrails

THE FLOW · A SYNTHETIC PATIENT

María, 58, diabetic, with an endocrinology visit and a scheduled knee surgery.

Moment	What the system detects	Action
7 days before	Her metformin is running out	WhatsApp to refill; the doctor approves the prescription
10 days before	Upcoming visit without lab results	The lab offers her a slot for HbA1c
3 days before	High no-show risk	Reinforced reminder and option to reschedule
Visit day	Results ready	The doctor receives an AI-generated summary
15 days before	Surgery confirmed	Bed reservation and insurer validation
2 days before	A pre-op test is missing	Alert to the surgeon and the patient; same-day cancellation avoided

PLATFORMS, CAPEX AND OPEX PER INITIATIVE (USD)

Initiative	Platforms	Months	CAPEX	OPEX / month
1 · Data foundations	Fabric F64, EMPI, HL7 engine, Health Data Services, Purview	0–4	450K	14.5K
2 · Patient 360	Power BI (physician viewing included in F64)	2–5	120K	1.0K
3 · Automation	Logic Apps, Functions, WhatsApp Business	4–8	200K	5.5K
4 · Predictive models	Azure Machine Learning	8–12	250K	3.0K
5 · Generative AI	Azure OpenAI, AI Search, Content Safety	12–15	200K	3.5K
Change, PMO and team	Five-person operations team	—	100K	25.0K
Total		**15**	**1,320K**	**52.5K**

Equivalents: AWS (HealthLake, SageMaker, Bedrock) and GCP (Healthcare API, Vertex AI). Everything runs in the cloud; no hardware purchase.

THE RESULT (ILLUSTRATIVE BUSINESS CASE)

CAPEX
1.32 M
one-time implementation investment

OPEX
0.63 M
per year, platforms and team

BENEFIT
1.37 M
per year: no-shows, refills, surgeries and collections

PAYBACK
≈ 21 months
at full operation

The non-negotiable principle

AI proposes and the physician decides. No refill, test or reservation is executed without human approval, and controlled medications stay out of automation. In healthcare, without trust the most accurate model goes unused.

THE FRAGILE ASSUMPTION

That medical records, pharmacy and billing can be reconciled into a single patient identifier. If the master index fails, every model inherits duplicates and notifies the wrong person. It is the lesson from Piece 6: the first phase ends in identity, not in a model.

WHAT I WOULD DO DIFFERENTLY

I would put the first use case in the hands of the pharmacy, not technology. Refills are what patients and doctors notice first, and the lever that funds the next phases fastest.

08 Predictive operations in retail

Seeing the failure before the store does, and knowing what it costs

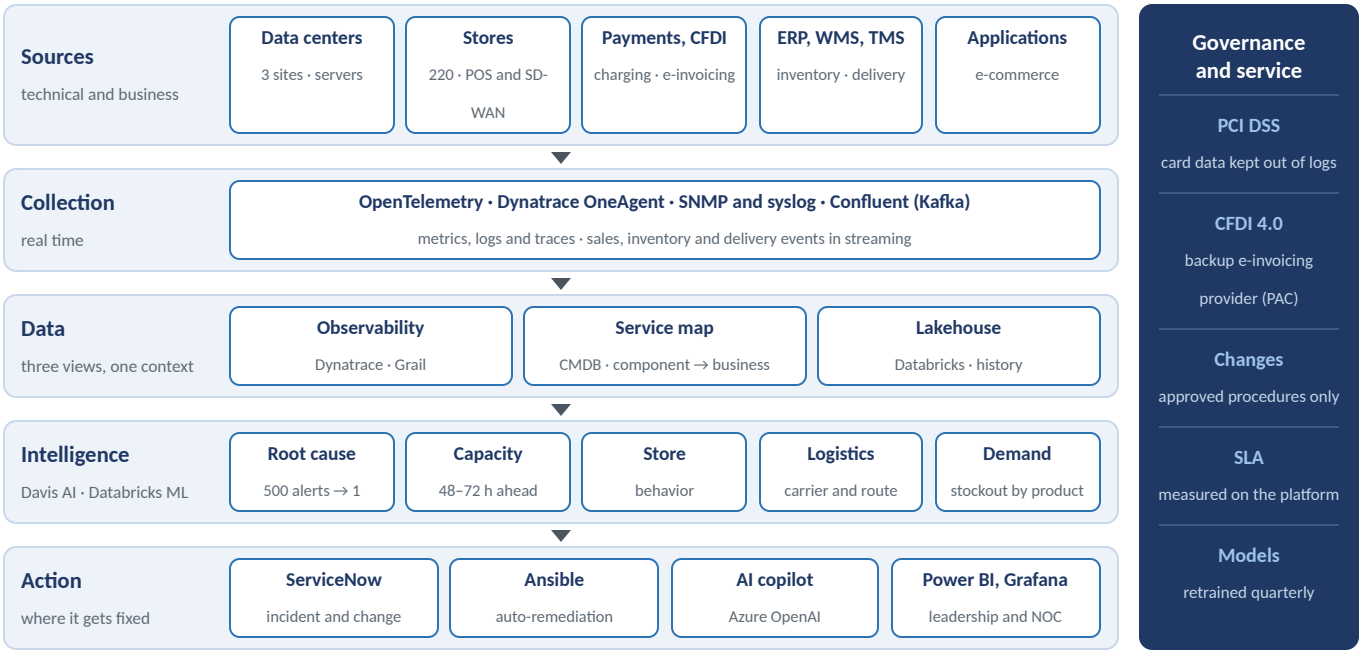
THE PROBLEM

A chain of more than 200 stores takes online and in-store payments on three data centers, under a support contract that includes the infrastructure. Today a failure is discovered when the register stops charging: thousands of uncorrelated alerts, no view of which sales or region are at risk, and inventory, deliveries and demand reviewed only after a stockout. Every outage costs sales, SLA penalties and trust.

THE METHOD

1. Instrument 3 data centers and 220 stores
2. Map every component to its line of business
3. Group alerts by root cause
4. Predict capacity and business deviations
5. Remediate only with approved procedures

THE ARCHITECTURE · FROM TECHNICAL SIGNAL TO SALES



SIX MODELS, SIX BUSINESS QUESTIONS

Model	Question	Suggested technique
Correlation and root cause	Which of the 500 alerts is the cause?	Topology graph and causality
Capacity saturation	When will payments or invoicing saturate?	Time series (Prophet, LSTM)
Log failures	Which pattern precedes an outage?	Log pattern clustering (Drain)
Store behavior	Which store sells or charges outside its pattern?	Isolation Forest, autoencoders
Carriers	Which carrier and which route are falling behind?	Delivery-time regression
Product demand	Which product will run out before replenishment?	Forecasting and anomaly detection

THE FLOW · A SYNTHETIC BUEN FIN (MEXICO'S BLACK FRIDAY)

Moment	What the system detects	Action
48 h before	Payments in the North DC will reach 92% capacity	Add capacity and balance with the West DC
Friday 18:40	Authorization latency 35% above its pattern	Davis AI groups 420 alerts into one incident
18:42	Root cause: a change in the payments database	Ansible rolls back the change with an approved procedure
18:44	Impact: 38 northern stores at risk	Notice to store managers and leadership
Saturday	The e-invoicing (CFDI) queue doubles	A second e-invoicing provider (PAC) is activated
Sunday	A carrier falls behind while demand rises	Replenishment from another distribution center

PLATFORMS, CAPEX AND OPEX PER INITIATIVE (USD)

Initiative	Platforms	Months	CAPEX	OPEX / month
1 · Observability	Dynatrace (DC, apps and logs), ThousandEyes (store network)	0–5	350K	52.0K
2 · AIOps and root cause	ServiceNow ITOM AIOps, CMDB and service map	3–8	300K	12.0K
3 · Business data	Databricks, Confluent (Kafka), Power BI	4–9	400K	20.0K
4 · Predictive models	Databricks ML	8–14	300K	5.0K
5 · Automation	Ansible Automation Platform, Azure OpenAI	12–18	250K	7.0K
Operations, PMO and team	Seven-person AIOps team	—	150K	35.0K
Total		**18**	**1,750K**	**131.0K**

Alternatives: Datadog or Splunk, BigPanda, Snowflake or Fabric, Rundeck. Assumes ServiceNow ITSM is already licensed. The three data centers stay on-premises; collectors run on the existing infrastructure.

THE RESULT (ILLUSTRATIVE 18-MONTH TARGETS)

MAJOR INCIDENTS
60 → 36
40% fewer per year

DETECTION
< 5 min
was 30 min; 70% before the store

RECOVERY
3 → 1.5 h
hours with sales impact: 180 → 54

PAYBACK
≈ 28 months
CAPEX 1.75 M · OPEX 1.57 M/yr · benefit 2.33 M/yr

The finding that changes the conversation

It is Piece 1 at scale: there, 17% of events were noise; here, one failure in the payments database produces hundreds of alerts. The value is not in reacting faster to each one, but in grouping them into one cause and linking it to the sales at risk. Without a service map, AI correlates but does not know what matters.

THE FRAGILE ASSUMPTION

The quality of the CMDB. Correlation and impact calculation depend on knowing which server supports which business service. With an outdated inventory, the model groups well and attributes badly; that is why phase 2 starts by reconciling inventory.

WHAT I WOULD DO DIFFERENTLY

I would negotiate retiring the current monitoring tools from phase 1. It is the saving the client feels first and the one that funds prediction, which is what takes longest to prove its value.

THE METHOD BEHIND THE EIGHT PIECES

How I work

The previous pieces deal with different problems, but they follow the same sequence. It is not a branded methodology: it is the discipline of not giving an opinion before measuring.

Five principles

1 · Raw data before the report

Aggregated reports hide exactly what needs to be seen. The hourly curve, the distribution by priority, the behavior of bursts: that only shows up in record-level detail. The data almost always already exists, and nobody has pulled it.

2 · Declare the fragile assumption

Every model rests on two or three assumptions, and usually one of them moves the result more than the others. Naming it explicitly makes the model defensible; hiding it makes it fragile. A model that does not declare where it can break is not a model, it is an opinion with a table.

3 · The artifact has to be usable

A diagnosis that ends in conclusions changes nothing. It ends in a template, a model with live formulas, a responsibility matrix, a shift proposal or a business case with CAPEX and OPEX: something someone can pick up on Monday and apply without translation.

4 · Adoption is part of the design, not a later phase

Transformation programs do not fail because of technical design, they fail because people do not adopt. If the model demands data entry nobody will do or governance nobody will sustain, it is badly designed even if it is correct. In AI this applies twice: the person who decides has to understand why the model recommends.

5 · Say what did not work

Every piece in this portfolio includes a section on what I would do differently. It is not modesty: it is the only section that shows independent judgment. Someone who can only narrate their successes has not yet learned from the project.

Where I add the most value

Situations where I fit

- Operations that grew without a method and do not know where they lose margin
- Transferring an operation to a third party while keeping control and accountability
- Multi-site or multi-country delivery that needs consistency without forced uniformity
- Data and AI programs that must prove return before scaling

What I usually find first

- The data exists and nobody has used it
- The team is not wrongly sized, it is wrongly distributed
- What is not declared as an exclusion gets absorbed in practice
- AI is requested before the data is reconciled
- The green indicator hides an exhausted team

CONVERSATIONS I AM INTERESTED IN

Operations that must sustain more with the same

Sizing and capacity with real data

Service governance and outsourced operations

Multi-site and multi-country operating models

Analytics and automation applied to delivery

Commercial intelligence with AI on operational data

Data and AI programs with a business case, CAPEX and OPEX

AIOps and predictive operations on critical infrastructure

Lázaro Gómez Ontiveros

lazarogomez@hotmail.com

+52 55 7980 3050

linkedin.com/in/lazarogomezontiveros

Mexico City · available for travel and relocation · Spanish, English and Portuguese

All data, figures, scenarios and examples in this document are synthetic and were built to illustrate method. They do not contain or reproduce information from any client, vendor or employer, past or present.

PORTAFOLIO PROFESIONAL

Lázaro Gómez Ontiveros

Operaciones de servicio basadas en datos
Método, modelos, gobierno y casos de IA aplicada

Chief Operations Officer · Servicios de tecnología

Operaciones multipaís en LATAM · Telecomunicaciones y servicios administrados

Ciudad de México · lazarogomez@hotmail.com · +52 55 7980 3050

Este documento presenta métodos y marcos de trabajo desarrollados a lo largo de mi carrera. Todos los datos, cifras y escenarios son sintéticos y fueron construidos para ilustrar el método. No contiene información de ningún cliente, proveedor ni empleador.

CÓMO LEER ESTE DOCUMENTO

Ocho piezas, un mismo método

Este portafolio no muestra proyectos: muestra cómo abordo un problema operativo. Cada pieza parte de una pregunta de negocio, aplica un método explícito y termina en un artefacto que alguien puede usar al día siguiente. Las piezas 7 y 8 llevan el mismo método a dos escenarios completos de datos e inteligencia artificial, con plataformas, CAPEX y OPEX.

> *Convierto operaciones de servicio que se gestionan por percepción en operaciones que se gestionan con datos, sin aumentar la plantilla.*

Contenido

#	Pieza	Pregunta que responde	Pág.
1	Dimensionamiento de cobertura con datos por hora	¿Cuánta gente necesito, en qué horario, y puedo ampliar servicio sin contratar?	3
2	Marco de acuerdo de nivel operativo	Si tercerizo la operación, ¿cómo conservo el control y la responsabilidad?	5
3	Modelo de cooperación entre preventa, ingeniería y operación	¿Cómo evito vender lo que la operación no puede sostener?	7
4	Tablero ejecutivo de operaciones	¿Qué debe mirar la dirección cada mes, y qué no?	9
5	Matriz de servicios y entregables por contrato	¿Cómo se traduce un catálogo comercial en obligaciones verificables?	11
6	Inteligencia comercial sobre datos operativos	¿Qué ofrecer a cada cliente, actual o nuevo, sin comprometer lo que la operación no sostiene?	13
7	**Paciente 360: datos e IA en un hospital privado** NUEVA	¿Cómo anticipo lo que cada paciente necesita, y cuánto cuesta construirlo y operarlo?	16
8	**Operación predictiva en retail** NUEVA	¿Cómo veo una falla o una desviación antes de que afecte la venta, y cuánto cuesta lograrlo?	18
—	Cómo trabajo	El método detrás de las ocho piezas	20

Trayectoria en una línea

EXPERIENCIA
20+
años en operaciones y tecnología

TELECOMUNICACIONES
21
años en operación de red y entrega de servicio

ALCANCE
LATAM
operación multipaís y multisitio

FORMACIÓN
MBA
ITAM (en curso) · Ing. Electrónica IPN · Chief AI Officer

Nota sobre los datos

Todos los números de este portafolio son sintéticos. Conservan la forma y el comportamiento típico de una operación —la curva horaria, la proporción entre prioridades, el efecto de las ráfagas, el orden de magnitud de un CAPEX— porque eso es lo que hace comprensible el método, pero no corresponden a ninguna organización real. Los precios de plataformas son de lista y referenciales. Los marcos de gobierno se presentan como plantillas genéricas, no como documentos de ningún contrato.

01 Dimensionamiento de cobertura con datos por hora

De la curva de demanda a la decisión de plantilla

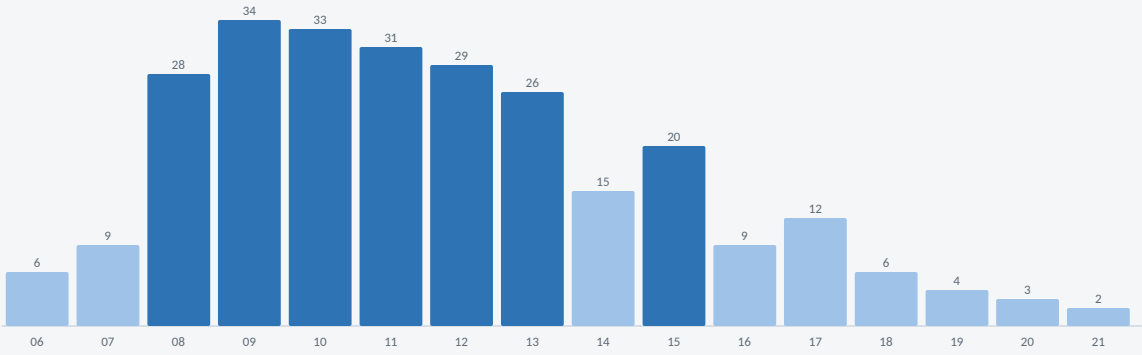
EL PROBLEMA

Un cliente pide ampliar la ventana de atención de 9 a 14 horas diarias. La respuesta intuitiva es contratar más personal y cotizar el incremento. La pregunta correcta es otra: ¿dónde está realmente la demanda dentro del día, y cuánta capacidad ya se está desperdiciando en las horas en que no ocurre nada?

EL MÉTODO

1	2	3	4	5
Extraer el detalle a nivel de registro, no el agregado mensual	Construir la curva de demanda por hora y normalizar ráfagas	Aplicar tiempo de atención y ocupación objetivo	Calcular recursos requeridos por franja con piso de cobertura	Diseñar turnos que cubran la ventana con la plantilla existente

PASO 1 · LA CURVA DE DEMANDA (DATOS SINTÉTICOS, EVENTOS DEL MES POR HORA)



Dos lecturas inmediatas. El grueso de la demanda vive entre las 08:00 y las 13:00, no repartido uniformemente en la jornada. Y las franjas 06:00–07:59 y 17:00–20:59 concentran un 16% de los eventos que hoy nadie atiende: ese es el argumento de la ampliación, y no hace falta suponerlo.

PASO 2 · SEPARAR DEMANDA REAL DE RUIDO

Las alertas automáticas generadas por un mismo evento raíz —una caída de enlace, una actualización de firmware— llegan como decenas de registros en minutos. Si no se agrupan en un ticket padre, distorsionan tres cosas a la vez: el dimensionamiento, la medición de cumplimiento y la percepción de carga del equipo. La normalización es el paso que más cambia el resultado y el que casi siempre se omite.

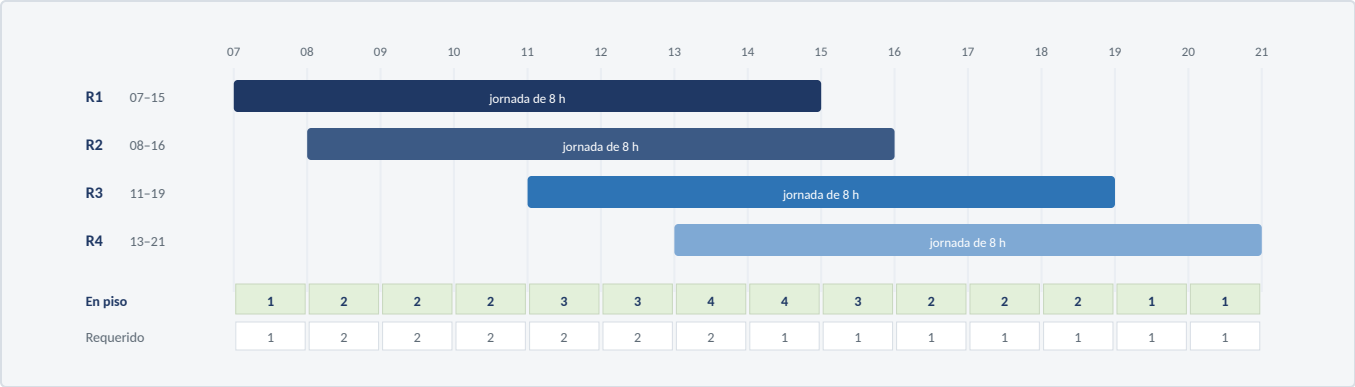
EVENTOS DEL MES	TRAS NORMALIZAR	DIFERENCIA
338	**281**	**17%**
volumen bruto observado	demanda real atribuible a usuarios	ruido de monitoreo, no carga operativa

PASO 3 · DE DEMANDA A RECURSOS POR FRANJA

La fórmula es deliberadamente simple, porque tiene que poder defenderse frente a un cliente y frente a finanzas: recursos por franja igual a eventos de la hora entre días hábiles, por tiempo de atención, entre ocupación objetivo, con un piso de un recurso en toda hora dentro de la ventana.

Supuesto	Valor	Por qué
Tiempo de atención	0.70 h	Mediana observada, no promedio: el promedio se distorsiona con los casos largos
Ocupación objetivo	70%	Deja 30% para comida, documentación, traslado y variabilidad
Días hábiles	21	Base mensual del periodo analizado
Piso de cobertura	1 recurso	Continuidad de servicio: ninguna hora de la ventana queda sin atención

PASO 4 · LA PROPUESTA DE TURNOS



Cuatro turnos escalonados de 8 horas cubren de 07:00 a 21:00. La fila superior es la plantilla en piso resultante; la inferior, el requerimiento calculado. El traslape de media tarde es deliberado: es la ventana de entrega de turno y comida escalonada.

EL RESULTADO

VENTANA DE SERVICIO
9 → 14 h
por día hábil

PLANTILLA
Sin cambio
los mismos recursos, redistribuidos

DEMANDA CUBIERTA
84 → 94%
+10 puntos de cobertura

El hallazgo que cambia la conversación

El requerimiento total de la ventana ampliada es de 17 recursos-hora al día y la plantilla en piso aporta 32. El problema nunca fue falta de gente: era que las cuatro personas estaban en la misma franja mientras el 16% de la demanda ocurría fuera de ella. La ampliación de horario no era un costo, era una redistribución.

QUÉ HARÍA DISTINTO

Mediría el tiempo de toque real desde el inicio en lugar de usar la mediana de tiempo de reloj. Es el único supuesto con peso material en el resultado: si el toque real fuera el doble, el pico sube a tres recursos y la conclusión cambia. Un modelo honesto declara cuál es su supuesto frágil.

02 Marco de acuerdo de nivel operativo

Qué firmar cuando la operación la ejecuta un tercero

EL PROBLEMA

Una compañía transfiere su operación a un proveedor y conserva la responsabilidad contractual frente al cliente. A partir de ese momento responde por un servicio que no ejecuta. La mayoría de los acuerdos que se firman en ese escenario cubren tiempos de respuesta y poco más, y dejan fuera justo lo que después duele.

EL PRINCIPIO QUE SOSTIENE TODO EL MARCO

> *El compromiso del proveedor debe ser más estricto que el que la compañía firmó con su cliente. La diferencia es el margen de gestión.*

Si ambos niveles son idénticos, cualquier desviación del proveedor se convierte en incumplimiento inmediato ante el cliente, sin espacio para validar, escalar ni comunicar. La regla práctica: el objetivo interno equivale al 80% del tiempo contratado, con un piso absoluto de margen en prioridad crítica.

Concepto	Comprometido al cliente	Objetivo del proveedor	Margen de gestión
Resolución P1	4 h	3 h	1 h
Resolución P2	6 h	4 h 30 min	1 h 30 min
Resolución P3	8 h	6 h	2 h
Disponibilidad mensual	99.0%	99.5%	0.5 puntos

LOS CINCO CAPÍTULOS QUE CASI NADIE INCLUYE

Capítulo	Qué previene
Bandas de volumen y gestión de demanda	Que cada variación de carga se renegocie sin regla. Se define volumen base, banda de tolerancia y precio marginal fuera de banda.
Continuidad operativa del proveedor	Que el acuerdo exija continuidad del servicio del cliente y no diga nada sobre las plataformas del propio operador. Se pide plan, tiempos de recuperación y prueba anual.
Cumplimiento laboral y subcontratación	La responsabilidad solidaria cuando hay personal en sitio del cliente. Evidencia periódica y autorización previa de subcontratistas.
Derecho de intervención y salida asistida	Que el escalón máximo de consecuencias sea una amenaza sin mecánica. Se define intervención temporal, causales y tarifa de salida preacordada desde el inicio.
Retorno de datos de operación	La pérdida silenciosa de capacidad de ingeniería: si el proveedor opera, el proveedor aprende. Se exige entrega mensual a nivel de registro, en formato explotable.

LA MATRIZ DE ENTREGABLES, EN AMBOS SENTIDOS

Un acuerdo que solo lista obligaciones del proveedor es un acuerdo incompleto: la mitad de los incumplimientos se originan en dependencias que el contratante no entregó a tiempo.

Del proveedor al contratante

Entregable	Frecuencia
Reporte de operación y cumplimiento	Mensual
Extracto de datos a nivel de registro	Mensual
Informe de causa raíz	Por evento
Inventario y configuración conciliados	Trimestral
Estado de plantilla y certificaciones	Trimestral
Notificación de incidente de seguridad	24 h / 72 h

Del contratante al proveedor

Entregable	Oportunidad
Paquete de diseño de servicio aprobado	Antes de operar
Runbooks probados	Antes de operar
Accesos y credenciales	Antes de operar
Requisitos de monitoreo y umbrales	Antes de operar
Soporte de tercer nivel	Bajo demanda
Aviso de cambio de alcance	30 a 60 días

EL RELEVO POR DEPENDENCIA INCUMPLIDA

Las exclusiones no operan solas. Para que el proveedor quede relevado del cómputo de tiempo por una dependencia ajena, debe avisarlo dentro de un plazo definido; sin aviso oportuno, el tiempo se le imputa. Es la cláusula que evita que la atribución de culpa aparezca por primera vez en el cierre mensual, cuando ya no es verificable.

CONSECUENCIAS ESCALONADAS, EN AMBAS DIRECCIONES

Nivel	Detonante	Consecuencia
1	Un mes bajo objetivo	Plan de acción documentado, con responsable y fecha
2	Dos meses consecutivos	Plan de remediación formal con revisión quincenal
3	Tres meses o penalización trasladada	Esquema económico y revisión de alcance
4	Incumplimiento reiterado o falla grave	Derecho de intervención y evaluación de continuidad

Y en sentido contrario: recuperación de créditos tras tres meses de recuperación sostenida, bonificación por desempeño y reparto del ahorro generado por automatización propuesta por el proveedor. Un acuerdo que solo castiga produce un proveedor que discute clasificaciones en lugar de resolver.

QUÉ HARÍA DISTINTO

Negociaría la tarifa de salida asistida al inicio del acuerdo, no al final. Es el único momento en que ambas partes tienen incentivo para ser razonables, y es exactamente la cláusula que nadie quiere discutir cuando la relación está empezando.

03 Cooperación entre preventa, ingeniería y operación

Cómo evitar vender lo que la operación no puede sostener

EL PROBLEMA

En muchas organizaciones de servicios, el diseño comercial lo hace preventa y la operación hereda el compromiso. Preventa se optimiza para ganar; el costo del error lo pagan ingeniería, la operación y el margen. La solución no es meter a ingeniería en cada oportunidad —eso la vuelve cuello de botella— sino separar dos cosas que hoy se llaman igual.

Diseño de solución

Qué se le vende al cliente: topología, marcas, alcance, propuesta de valor. Actividad comercial, sensible al tiempo. Le corresponde a preventa.

Diseño de servicio

Cómo se opera y sostiene durante 24 o 36 meses: niveles, dimensionamiento, costos, perfiles, herramientas, runbooks, criterios de aceptación y salida. Lo gobierna ingeniería.

EL FLUJO CON TRES COMPUERTAS



Compuerta	Qué decide	Quién aprueba
G1 · Calificación	Si la oportunidad es estándar o excepción. Fuera de catálogo, marca nueva, nivel distinto o servicio nunca operado pasa a diseño.	Preventa, con criterio definido por ingeniería
G2 · Operabilidad	Si la operación puede sostener lo que se va a comprometer, al nivel y al costo propuestos. Requiere firma conjunta.	Operación, con revisión de ingeniería
G3 · Transición	Si el servicio puede entrar en producción: runbooks probados, monitoreo activo, inventario conciliado, personal capacitado.	Operación acepta contra criterios

EL MECANISMO QUE EVITA EL CUELLO DE BOTELLA

Si ingeniería revisara cada oportunidad, ninguna propuesta saldría a tiempo. La salida es prediseñar: un catálogo de patrones de servicio ya aprobados —nivel base, modelo de capacidad, costo unitario, perfiles, herramientas, runbook tipo— del que preventa arma cotizaciones ensamblando bloques. El objetivo es que el 80% de las oportunidades no requiera ciclo de ingeniería.

VÍA ESTÁNDAR
80%
de oportunidades resueltas desde catálogo

CICLO DE PROPUESTA
< 6 días
objetivo sostenible con catálogo publicado

EXCEPCIONES
→ catálogo
cada excepción vendida una vez se industrializa

MATRIZ DE RESPONSABILIDAD

A: único aprobador · R: ejecuta · C: consultado · I: informado

Actividad	Preventa	Arquitectura	Ingeniería	Operación	PMO
Calificación de la oportunidad	A/R	C	I	I	I
Propuesta comercial	A/R	C	I	I	C
Catálogo y estándares de diseño	I	A	R	C	I
Paquete de diseño de servicio	C	A	R	C	I
Dimensionamiento y capacidad	I	A	R	C	C
Validación de operabilidad	I	C	R	A	I
Costeo final y tiempos de entrega	C	I	C	I	A/R
Aprobación técnica previa a firma	I	A/R	C	C	C
Implementación y transición	I	C	A/R	C	R
Operación bajo niveles acordados	I	I	A	R	C
Mejora del diseño	I	A	R	R	I

Las dos asignaciones que siempre se discuten

En la validación de operabilidad el aprobador es la operación, no ingeniería: quien va a operar debe poder decir que no. Ingeniería conserva su freno propio en la aprobación técnica previa a la firma. Son dos controles distintos y ninguno sustituye al otro.

En la operación diaria la ejecución es del proveedor u operación, pero la rendición de cuentas permanece en ingeniería de entrega, porque la compañía responde ante el cliente aunque no ejecute.

QUÉ HARÍA DISTINTO

Publicaría el catálogo antes de activar las compuertas. Si el modelo de gobierno entra en vigor sin catálogo, toda oportunidad se vuelve excepción e ingeniería se convierte exactamente en el cuello de botella que el diseño pretendía evitar. El orden importa más que el diseño.

04 Tablero ejecutivo de operaciones

Siete indicadores, tres preguntas, una página

EL PROBLEMA

Los tableros operativos fracasan por exceso, no por falta. Cuarenta indicadores en una pantalla producen la misma parálisis que ninguno. La disciplina consiste en elegir el mínimo conjunto que permita a la dirección responder tres preguntas y decidir.

¿Estamos cumpliendo?

Salud del servicio comprometido. Si esto falla, todo lo demás es irrelevante.

¿Estamos ganando dinero?

Rentabilidad real de la entrega, no la proyectada al firmar.

¿Vamos a poder sostenerlo?

Capacidad, talento y demanda futura. Es el pilar que nadie mira hasta que truena.

LOS SIETE INDICADORES

Pilar	Indicador	Por qué este y no otro
Servicio	Cumplimiento de niveles acordados	Es el compromiso contractual: define si hay penalización
Servicio	Resolución al primer contacto	Único indicador que mejora costo y experiencia al mismo tiempo
Servicio	Reincidencia de incidentes	Distingue la mejora estructural del apagafuegos eficiente
Finanzas	Margen real por contrato	Contra el margen diseñado: la desviación revela el problema antes que el estado de resultados
Finanzas	Días de cobranza	El servicio puede ser rentable y la cuenta seguir destruyendo caja
Sostenibilidad	Utilización de capacidad	Por debajo del 65% hay grasa; por encima del 85% se rompe
Sostenibilidad	Rotación del equipo	El indicador más honesto de si el modelo operativo es sostenible

El principio de diseño

Cada indicador debe poder abrirse hasta la evidencia que lo originó: del porcentaje al contrato, del contrato al ticket. Un número que no se puede rastrear se discute en el comité en lugar de decidirse. La trazabilidad no es una función del tablero, es su condición de existencia.

CÓMO SE VE (DATOS SINTÉTICOS)

Tablero de Operaciones · Cierre mensual — Vista de dirección

SERVICIO

CUMPLIMIENTO DE SLA
96.8%

meta 96.0% · en meta

PRIMER CONTACTO
58%

meta 60% · cerca

REINCIDENCIA
7.4%

meta ≤ 6% · en avance

FINANZAS

MARGEN REAL VS. DISEÑADO
−3.2 pp

desviación acumulada · atención

DÍAS DE COBRANZA
74 d

objetivo 60 d · deteriorando

SOSTENIBILIDAD

UTILIZACIÓN DE CAPACIDAD
78%

rango óptimo 72–82% · saludable

ROTACIÓN ANUALIZADA
24%

tolerancia 20% · fuera

LA LECTURA QUE IMPORTA

Este tablero sintético cuenta una historia que un tablero de solo servicio ocultaría: el cumplimiento mejora seis meses seguidos, pero el margen se deteriora y la rotación se dispara. Es el patrón clásico de una operación que está comprando desempeño con esfuerzo del equipo. El servicio se ve bien hoy y se va a romper en dos trimestres.

Por qué el pilar de sostenibilidad existe

Sin él, la dirección felicita al equipo por el indicador verde y se entera del problema cuando renuncian tres personas clave. Rotación y utilización no son métricas de recursos humanos: son los indicadores adelantados del servicio del año que viene.

QUÉ HARÍA DISTINTO

Agregaría un octavo indicador de calidad del dato —registros sin responsable asignado, cierres sin causa raíz— en la primera versión y no en la segunda. Todos los demás números dependen de él, y cuando falla, el tablero no se equivoca: miente con confianza.

05 De catálogo comercial a obligaciones verificables

La matriz que traduce lo que se vende en lo que se debe entregar

EL PROBLEMA

El catálogo comercial dice qué incluye cada modalidad de contrato. La operación necesita otra cosa: quién ejecuta cada servicio, quién responde por él y qué entrega, con qué frecuencia y en qué plazo. Entre esos dos documentos suele haber un vacío, y ese vacío es donde se absorbe trabajo no contratado y se pierde margen sin que nadie lo registre.

ESTRUCTURA DE MODALIDADES (EJEMPLO GENÉRICO DE CUATRO NIVELES)

Elemento	Básico	Extendido	Gestionado	A medida
Ventana de atención	8x5	24x7	24x7	Según contrato
Modalidad	Reactivo	Reactivo	Reactivo y gestionado	Proactivo y gestionado
Monitoreo	—	—	Incluido	Incluido
Análisis de causa raíz	—	Incluido	Incluido	Incluido
Gestión de capacidad	—	—	Incluido	Según contrato
Mantenimiento preventivo	—	—	Incluido	—
Penalizaciones	No aplican	No aplican	Aplican	Aplican

La observación que suele pasar desapercibida

La modalidad extendida tiene ventana continua con servicio puramente reactivo y sin monitoreo. Eso significa sostener disponibilidad de atención las 24 horas sin detección automática: la demanda entra solo cuando el cliente reporta. Su plantilla se dimensiona por cobertura, no por volumen, y es casi siempre la modalidad menos rentable del catálogo. Detectarlo antes de firmar es la diferencia entre un contrato sano y uno que se defiende durante dos años.

SERVICIOS EXCLUIDOS, DECLARADOS COMO TALES

Lo que no está incluido debe escribirse con la misma precisión que lo incluido. Sin declaración expresa, la operación termina absorbiéndolo de hecho: guardias por evento especial, gestión de proveedores del cliente, levantamientos de sitio, trabajo en alturas, stock propio de refacciones. Cada uno lleva su implicación operativa anotada, para que la conversación comercial sea informada.

LA COLUMNA QUE CONVIERTE UN CATÁLOGO EN UN ACUERDO OPERATIVO

No es la de aplicabilidad, sino la de ejecución: quién hace cada cosa cuando la operación está repartida entre la compañía y un tercero.

Servicio	Práctica	Ejecución y responsabilidad
Mesa de servicio	Incidentes	Ejecuta el operador · responde la compañía ante el cliente
Soporte remoto N1 y N2	Incidentes	Ejecuta el operador · escala a tercer nivel propio
Seguimiento con fabricante	Incidentes	Gestiona suministro propio · el operador aporta evidencia técnica
Gestión de cambios normales	Cambios	Ejecuta el operador · autoriza ingeniería propia
Monitoreo	Eventos	Opera el proveedor · umbrales y severidades los define la compañía
Gestión de capacidad	Capacidad	Ingeniería propia, con los datos que entrega el operador
Inventario y configuración	Activos	Mantiene el operador · el registro de referencia es de la compañía
Mejora continua	Mejora	Propone ingeniería propia · ejecuta el operador bajo control de cambios

ENTREGABLES: LOS COMERCIALES Y LOS QUE NADIE ESCRIBE

Comprometidos al cliente

Entregable	Plazo
Reporte por evento en sitio	24 h hábiles
Análisis de causa raíz	5 días hábiles
Control de cambios	Antes de ejecutar
Reporte mensual de cumplimiento	Día hábil 3
Reporte de inventario	Día hábil 5

Internos, no visibles al cliente

Entregable	Frecuencia
Datos de operación a nivel registro	Mensual
Conciliación de inventario en sitio	Trimestral
Estado de plantilla y certificaciones	Trimestral
Bitácora de desviaciones de diseño	Mensual
Registro de ráfagas agrupadas	Mensual

Por qué los entregables internos importan más

Los comerciales se revisan en el comité con el cliente y nadie los olvida. Los internos no los reclama nadie, y son justamente los que preservan la capacidad de diseñar: sin el dato de operación a nivel de registro, la organización pierde en dos o tres ciclos contractuales la información que necesita para dimensionar, cotizar y mejorar. Es una degradación silenciosa.

QUÉ HARÍA DISTINTO

Fijaría la lista de verificación antes de negociar la primera cuenta y no después de la tercera. Doce puntos —ventana confirmada, distinción entre respuesta y resolución, catálogo de peticiones, umbrales, esquema de penalización, exclusiones declaradas— evitan la mayoría de las discusiones que después se resuelven concediendo.

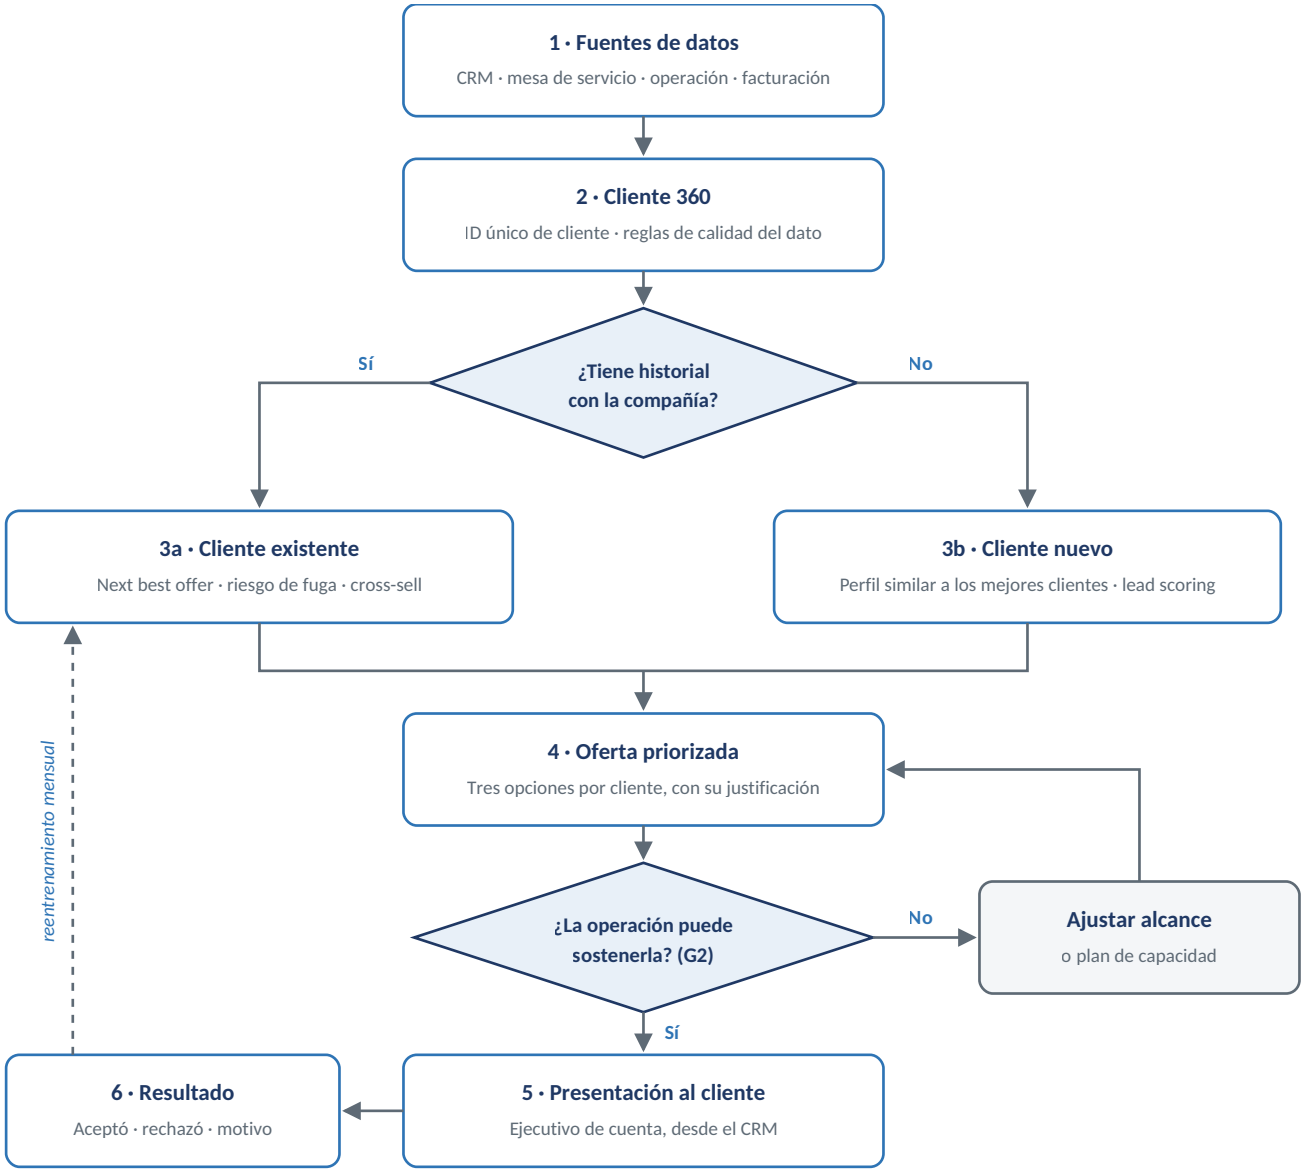
06 Inteligencia comercial sobre datos operativos

Qué ofrecer a cada cliente, sin vender lo que la operación no puede sostener

EL PROBLEMA

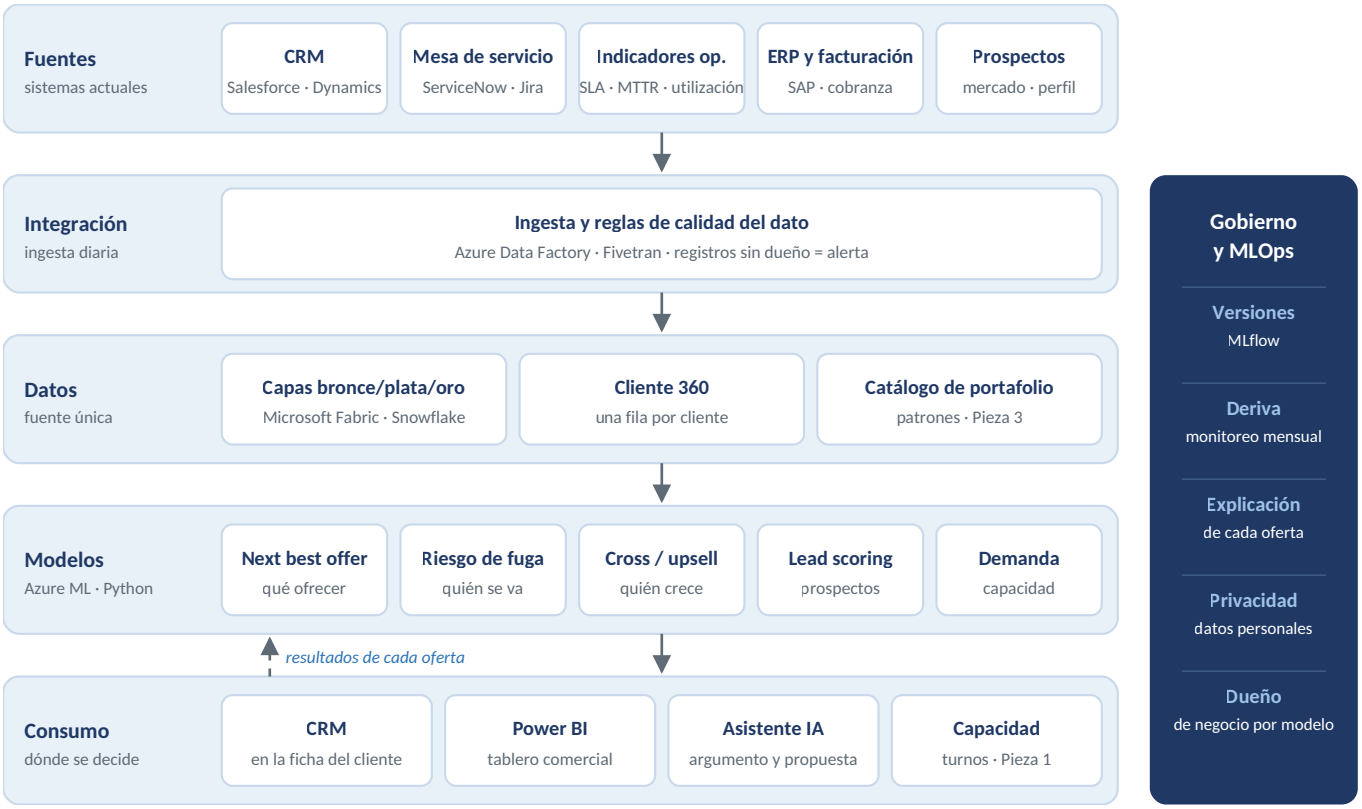
Ventas decide qué ofrecer por intuición y por meta trimestral; la operación sabe qué cliente está saturando su capacidad, cuál vive con el SLA al límite y cuál paga tarde. Esa información existe, pero vive en sistemas que no se hablan. El resultado: se ofrece lo mismo a todos, se pierde al cliente que ya daba señales y se vende lo que después nadie puede sostener.

EL FLUJO · DEL DATO OPERATIVO A LA OFERTA



El rombo inferior es la misma compuerta de operabilidad de la Pieza 3: ninguna recomendación llega al cliente sin que la operación confirme que puede sostenerla al nivel y al costo propuestos. Cada resultado, aceptado o rechazado, vuelve a entrenar el modelo.

LA ARQUITECTURA · CINCO CAPAS Y UN GOBIERNO TRANSVERSAL



Las herramientas son ejemplos sustituibles: la arquitectura se adapta al ecosistema que la compañía ya tiene. Lo que no se sustituye es la capa de cliente 360 ni el gobierno.

CINCO MODELOS, CINCO PREGUNTAS DE NEGOCIO

Modelo	Pregunta	Señales que usa	Técnica sugerida
Next best offer	¿Qué le ofrezco a este cliente ahora?	Historial de compra, uso real del servicio, clientes similares	Gradient boosting · filtrado colaborativo
Riesgo de fuga	¿Quién se va a ir si no hago nada?	SLA incumplidos, reincidencia, días de cobranza, tickets	Clasificación · gradient boosting
Cross-sell y upsell	¿Quién puede crecer, y hacia qué modalidad?	Modalidad contratada vs. uso real, capacidad excedida	Clasificación + reglas de catálogo
Lead scoring	¿Qué prospecto se parece a mis mejores clientes?	Industria, tamaño, región, perfil de los clientes más rentables	Perfil similar (look-alike)
Pronóstico de demanda	¿Podré sostener lo que se va a vender?	Pipeline, estacionalidad, curva horaria de demanda	Series de tiempo

Por qué no una sola red neuronal

Con datos de negocio en tablas —ventas, tickets, indicadores— los modelos de gradient boosting igualan o superan a las redes neuronales con menos datos, y se pueden explicar a un director comercial. Las redes neuronales se reservan para texto: correos y tickets, donde el motivo de insatisfacción no está en ningún campo estructurado.

EJEMPLO SINTÉTICO · CUATRO CLIENTES, CUATRO DECISIONES

Cliente	Modalidad	Señal operativa	Fuga	Recomendación	¿Operable?
Cliente A	Básico 8x5	22% de sus tickets llegan fuera de horario	Bajo	Extendido con ventana ampliada	Sí: redistribución de turnos, sin contratar (Pieza 1)
Cliente B	Gestionado	SLA 91% y reincidencia 12% tres meses seguidos	Alto	Ninguna: plan de retención primero	No aplica hasta recuperar el servicio
Cliente C	Extendido	Capacidad al 92% durante un trimestre	Medio	Gestión de capacidad	Sí, dentro de catálogo
Prospecto D	—	Perfil similar al 10% más rentable de la cartera	—	Gestionado	Requiere validación de operabilidad (G2)

El cliente B es el caso que justifica todo el modelo: sin datos de servicio, ventas le habría ofrecido un upgrade a un cliente que está a punto de irse.

LA OFERTA · INTELIGENCIA COMERCIAL OPERATIVA EN TRES FASES

Fase	Duración	Qué se entrega	Criterio para avanzar
1 · Diagnóstico de datos	4 semanas	Inventario de fuentes, ID único de cliente, informe de calidad del dato, casos de uso priorizados	80% de clientes conciliados entre CRM, servicio y facturación
2 · Piloto	8–10 semanas	Riesgo de fuga y next best offer en un segmento; recomendación visible en el CRM; tablero	Ejecutivos usan la recomendación en al menos 30% de sus cuentas
3 · Escalamiento	3–6 meses	Cinco modelos, MLOps, conexión con planeación de capacidad y asistente de IA generativa	Margen real de lo vendido igual o mayor al diseñado

CÓMO SE MIDE (METAS ILUSTRATIVAS)

CONVERSIÓN
+15%
ofertas aceptadas vs. oferta genérica

RETENCIÓN
−20%
fuga en clientes marcados en riesgo

CICLO DE PROPUESTA
< 6 d
con oferta y catálogo prearmados

MARGEN
≥ 0 pp
desviación real vs. diseñado

EL SUPUESTO FRÁGIL

Que el CRM, la mesa de servicio y la facturación compartan un identificador de cliente. Si no lo hacen, los modelos aprenden de registros mal atribuidos y recomiendan con confianza sobre datos equivocados. Por eso la primera fase termina en conciliación de clientes, no en un modelo: es el trabajo menos vistoso y el que decide si todo lo demás sirve.

Dónde encaja esta oferta

En roles de dirección de operaciones, entrega de servicios administrados o transformación digital, donde la operación deja de verse como centro de costo y se convierte en fuente de crecimiento: los mismos datos que sostienen el SLA deciden qué vender, a quién y cuándo.

07 Paciente 360: datos e IA en un hospital privado

Anticipar lo que cada paciente necesita, y saber cuánto cuesta construirlo y operarlo

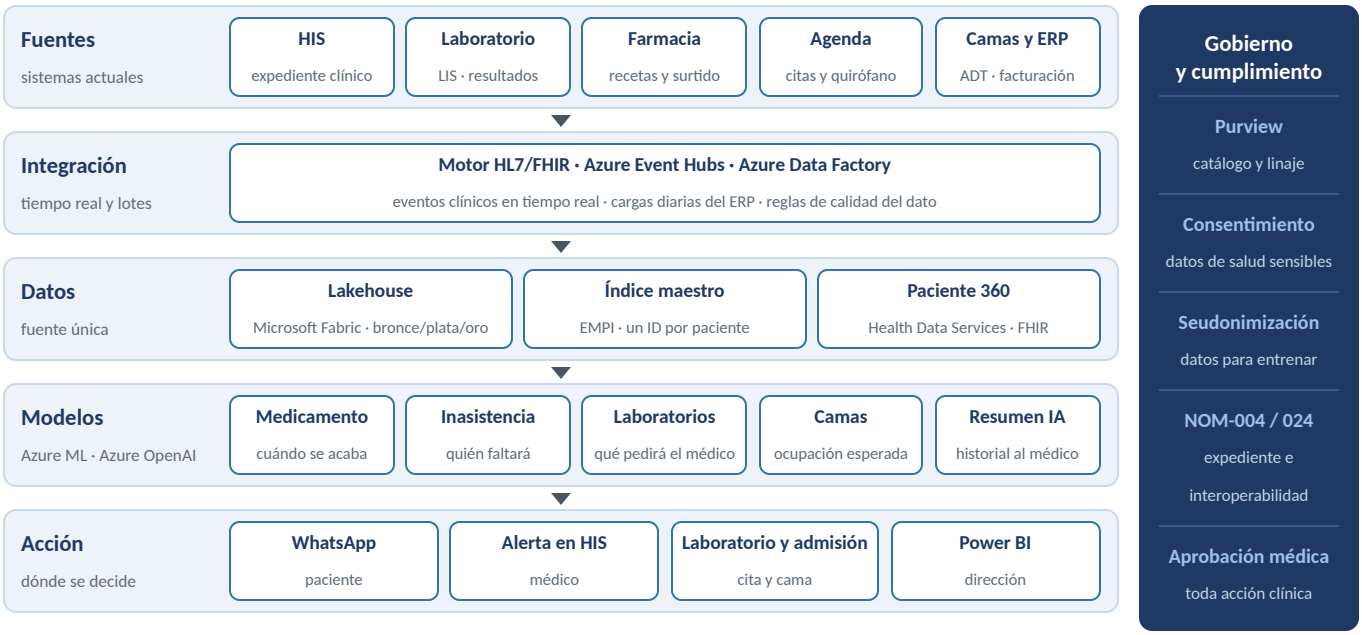
EL PROBLEMA

Un hospital privado tiene al paciente repartido en siete sistemas que no se hablan: expediente, agenda, farmacia, laboratorio, quirófano, camas y facturación. El costo aparece en citas perdidas, tratamientos interrumpidos, cirugías canceladas el mismo día y saldos que se descubren al alta. La pregunta no es qué modelo de IA usar, sino cómo convertir siete registros parciales en una vista que actúe antes del problema.

EL MÉTODO

1	2	3	4	5
Unificar identidad: un ID único de paciente (EMPI)	Construir la vista 360 sobre el estándar FHIR	Modelos que anticipan, no que reportan	Orquestar acciones con aprobación médica	Medir línea base y escalar por fases

LA ARQUITECTURA · CINCO CAPAS Y UN GOBIERNO TRANSVERSAL



SEIS MODELOS, SEIS PREGUNTAS DE NEGOCIO

Modelo	Pregunta	Técnica sugerida
Agotamiento de medicamento	¿Cuándo se le acaba, y lo resurtirá aquí?	Reglas + regresión de adherencia
Inasistencia	¿Quién va a faltar a su cita?	Clasificación · gradient boosting
Laboratorios previos	¿Qué estudios pedirá el médico en la consulta?	Reglas clínicas + recomendación
Demanda de camas	¿Cuántas camas por día y tipo?	Series de tiempo
Reingreso y cobranza	¿Qué paciente o qué cuenta está en riesgo?	Clasificación y scoring
Resumen pre-consulta	¿Qué debe saber el médico en 30 segundos?	IA generativa con controles

EL FLUJO · UNA PACIENTE SINTÉTICA

María, 58 años, diabética, con consulta de endocrinología y cirugía de rodilla programada.

Momento	Qué detecta el sistema	Acción
7 días antes	Su metformina se acaba	WhatsApp para resurtir; el médico aprueba la receta
10 días antes	Consulta próxima sin laboratorios	Laboratorio le propone horario para HbA1c
3 días antes	Riesgo alto de inasistencia	Recordatorio reforzado y opción de reprogramar
Día de consulta	Resultados listos	El médico recibe un resumen generado con IA
15 días antes	Cirugía confirmada	Reserva de cama y validación con la aseguradora
2 días antes	Falta un estudio preoperatorio	Alerta al cirujano y a la paciente; se evita cancelar el mismo día

PLATAFORMAS, CAPEX Y OPEX POR INICIATIVA (USD)

Iniciativa	Plataformas	Meses	CAPEX	OPEX / mes
1 · Fundamentos de datos	Fabric F64, EMPI, motor HL7, Health Data Services, Purview	0–4	450 mil	14.5 mil
2 · Paciente 360	Power BI (consulta de médicos incluida en F64)	2–5	120 mil	1.0 mil
3 · Automatización	Logic Apps, Functions, WhatsApp Business	4–8	200 mil	5.5 mil
4 · Modelos predictivos	Azure Machine Learning	8–12	250 mil	3.0 mil
5 · IA generativa	Azure OpenAI, AI Search, Content Safety	12–15	200 mil	3.5 mil
Cambio, PMO y equipo	Equipo de operación de 5 personas	—	100 mil	25.0 mil
Total		**15**	**1,320 mil**	**52.5 mil**

Equivalentes: AWS (HealthLake, SageMaker, Bedrock) y GCP (Healthcare API, Vertex AI). Todo corre en la nube; no hay compra de hardware.

EL RESULTADO (CASO DE NEGOCIO ILUSTRATIVO)

CAPEX
1.32 M
inversión única de implementación

OPEX
0.63 M
al año, plataformas y equipo

BENEFICIO
1.37 M
al año: inasistencias, resurtido, cirugías y cobranza

RECUPERACIÓN
≈ 21 meses
en operación plena

El principio que no se negocia

La IA propone y el médico decide. Ningún resurtido, estudio o reserva se ejecuta sin aprobación humana, y los medicamentos controlados quedan fuera de la automatización. En salud, sin confianza el modelo más preciso no se usa.

EL SUPUESTO FRÁGIL

Que expediente, farmacia y facturación puedan conciliarse en un identificador único de paciente. Si el índice maestro no lo logra, cada modelo hereda duplicados y notifica a la persona equivocada. Es la lección de la Pieza 6: la primera fase termina en identidad, no en un modelo.

QUÉ HARÍA DISTINTO

Pondría el primer caso de uso en manos de farmacia y no de tecnología. El resurtido es lo que paciente y médico perciben primero, y la palanca que financia más rápido las fases siguientes.

08 Operación predictiva en retail

Ver la falla antes de que la vea la tienda, y saber cuánto cuesta lograrlo

EL PROBLEMA

Una cadena de más de 200 tiendas cobra en línea y en tienda sobre tres centros de datos, con un contrato de soporte que incluye la infraestructura. Hoy la falla se descubre cuando la caja ya no cobra: miles de alertas sin correlación, sin saber qué venta o región está en riesgo, e inventario, entregas y demanda revisados cuando ya hubo quiebre. Cada interrupción cuesta venta, penalizaciones de SLA y confianza.

EL MÉTODO

1	2	3	4	5
Instrumentar 3 centros de datos y 220 tiendas	Mapear cada componente a su línea de negocio	Agrupar alertas por causa raíz	Predecir capacidad y desviaciones de negocio	Remediar solo con procedimientos aprobados

LA ARQUITECTURA · DE LA SEÑAL TÉCNICA A LA VENTA

Fuentes (técnicas y de negocio)
- Centros de datos — 3 sitios · servidores
- Tiendas — 220 · cajas y SD-WAN
- Pagos y CFDI — cobro y timbrado
- ERP, WMS, TMS — inventario y entregas
- Aplicaciones — e-commerce

Recolección (tiempo real)
- OpenTelemetry · Dynatrace OneAgent · SNMP y syslog · Confluent (Kafka) — métricas, logs y trazas · eventos de venta, inventario y entregas en streaming

Datos (tres vistas, un contexto)
- Observabilidad — Dynatrace · Grail
- Mapa de servicios — CMDB · componente → negocio
- Lakehouse — Databricks · historia

Inteligencia (Davis AI · Databricks ML)
- Causa raíz — 500 alertas → 1
- Capacidad — 48–72 h antes
- Tienda — comportamiento
- Logística — transportista y ruta
- Demanda — quiebre por producto

Acción (dónde se corrige)
- ServiceNow — incidente y cambio
- Ansible — autorremediación
- Copiloto IA — Azure OpenAI
- Power BI y Grafana — dirección y operación

Gobierno y servicio

- **PCI DSS** — tarjeta fuera de los logs
- **CFDI 4.0** — segundo PAC de timbrado
- **Cambios** — solo procedimientos aprobados
- **SLA** — medidos en la plataforma
- **Modelos** — reentrenados cada trimestre

SEIS MODELOS, SEIS PREGUNTAS DE NEGOCIO

Modelo	Pregunta	Técnica sugerida
Correlación y causa raíz	¿Cuál de las 500 alertas es la causa?	Grafo de topología y causalidad
Saturación de capacidad	¿Cuándo se satura el cobro o la facturación?	Series de tiempo (Prophet, LSTM)
Fallas en logs	¿Qué patrón precede a una caída?	Agrupación de patrones (Drain)
Comportamiento por tienda	¿Qué tienda vende o cobra fuera de su patrón?	Isolation Forest, autoencoders
Transportistas	¿Qué proveedor y qué ruta se están retrasando?	Regresión de tiempos de entrega
Demanda por producto	¿Qué producto se agotará antes del reabasto?	Pronóstico y detección de anomalías

EL FLUJO · UN BUEN FIN SINTÉTICO

Momento	Qué detecta el sistema	Acción
48 h antes	Pagos en el DC Norte llegará a 92% de capacidad	Ampliar capacidad y balancear con DC Occidente
Viernes 18:40	Latencia de autorización 35% sobre su patrón	Davis AI agrupa 420 alertas en un incidente
18:42	Causa raíz: un cambio en la base de pagos	Ansible revierte el cambio con procedimiento aprobado
18:44	Impacto: 38 tiendas del norte en riesgo	Aviso a gerentes de tienda y a dirección
Sábado	La cola del timbrado CFDI crece al doble	Se activa un segundo PAC de timbrado
Domingo	Retraso de un transportista y demanda al alza	Reabasto desde otro centro de distribución

PLATAFORMAS, CAPEX Y OPEX POR INICIATIVA (USD)

Iniciativa	Plataformas	Meses	CAPEX	OPEX / mes
1 · Observabilidad	Dynatrace (DC, apps y logs), ThousandEyes (red de tiendas)	0–5	350 mil	52.0 mil
2 · AIOps y causa raíz	ServiceNow ITOM AIOps, CMDB y mapa de servicios	3–8	300 mil	12.0 mil
3 · Datos de negocio	Databricks, Confluent (Kafka), Power BI	4–9	400 mil	20.0 mil
4 · Modelos predictivos	Databricks ML	8–14	300 mil	5.0 mil
5 · Automatización	Ansible Automation Platform, Azure OpenAI	12–18	250 mil	7.0 mil
Operación, PMO y equipo	Equipo de AIOps de 7 personas	—	150 mil	35.0 mil
Total		**18**	**1,750 mil**	**131.0 mil**

Alternativas: Datadog o Splunk, BigPanda, Snowflake o Fabric, Rundeck. Supone ServiceNow ITSM ya licenciado. Los tres centros de datos permanecen en sitio; los colectores usan la infraestructura actual.

EL RESULTADO (METAS ILUSTRATIVAS A 18 MESES)

INCIDENTES MAYORES
60 → 36
40% menos al año

DETECCIÓN
< 5 min
antes 30 min; 70% antes que la tienda

RECUPERACIÓN
3 → 1.5 h
horas con impacto en venta: 180 → 54

INVERSIÓN
≈ 28 meses
CAPEX 1.75 M · OPEX 1.57 M/año · beneficio 2.33 M/año

El hallazgo que cambia la conversación

Es la Pieza 1 a escala: ahí, el 17% de los eventos era ruido; aquí, una falla en la base de pagos produce cientos de alertas. El valor no está en reaccionar más rápido a cada una, sino en agruparlas en una causa y ligarla con la venta en riesgo. Sin mapa de servicios, la IA correlaciona pero no sabe qué importa.

EL SUPUESTO FRÁGIL

La calidad de la CMDB. La correlación y el cálculo de impacto dependen de saber qué servidor soporta qué servicio de negocio. Con un inventario desactualizado, el modelo agrupa bien y atribuye mal; por eso la fase 2 empieza conciliando inventario.

QUÉ HARÍA DISTINTO

Negociaría el retiro de las herramientas de monitoreo actuales desde la fase 1. Es el ahorro que el cliente siente primero y el que financia la predicción, que es lo que más tarda en demostrar valor.

EL MÉTODO DETRÁS DE LAS OCHO PIEZAS

Cómo trabajo

Las piezas anteriores tratan problemas distintos, pero siguen la misma secuencia. No es una metodología con nombre: es la disciplina de no opinar antes de medir.

Cinco principios

1 · El dato crudo antes que el reporte

Los reportes agregados esconden justamente lo que hay que ver. La curva horaria, la distribución por prioridad, el comportamiento de las ráfagas: eso solo aparece en el detalle a nivel de registro. Casi siempre el dato ya existe y nadie lo ha bajado.

2 · Declarar el supuesto frágil

Todo modelo descansa en dos o tres supuestos, y normalmente uno de ellos mueve el resultado más que los demás. Nombrarlo explícitamente hace el modelo defendible; esconderlo lo hace frágil. Un modelo que no declara dónde puede romperse no es un modelo, es una opinión con tabla.

3 · El artefacto tiene que poder usarse

Un diagnóstico que termina en conclusiones no cambia nada. Termina en una plantilla, un modelo con fórmulas vivas, una matriz de responsabilidad, una propuesta de turnos o un caso de negocio con CAPEX y OPEX: algo que alguien pueda tomar el lunes y aplicar sin traducción.

4 · La adopción es parte del diseño, no una fase posterior

Los programas de transformación no fracasan por diseño técnico, fracasan porque la gente no adopta. Si el modelo exige captura que nadie va a hacer o gobierno que nadie va a sostener, está mal diseñado aunque sea correcto. En IA aplica doble: la persona que decide tiene que entender por qué el modelo recomienda.

5 · Decir lo que no funcionó

Cada pieza de este portafolio incluye un apartado sobre qué haría distinto. No es modestia: es el único apartado que demuestra criterio propio. Quien solo puede narrar sus aciertos todavía no ha aprendido del proyecto.

Dónde aporto más

Situaciones donde encajo

- Operaciones que crecieron sin método y no saben dónde pierden margen
- Transferencia de operación a un tercero, conservando control y responsabilidad
- Entrega multisitio o multipaís que necesita consistencia sin uniformidad forzada
- Programas de datos e IA que deben demostrar retorno antes de escalar

Lo que suelo encontrar primero

- El dato existe y nadie lo ha explotado
- La plantilla no está mal dimensionada, está mal distribuida
- Lo que no está declarado como exclusión se absorbe de hecho
- Se pide IA antes de tener el dato conciliado
- El indicador verde esconde un equipo agotado

CONVERSACIONES QUE ME INTERESAN

Operaciones que deben sostener más con lo mismo

Dimensionamiento y capacidad con datos reales

Gobierno de servicio y operación tercerizada

Modelos operativos multisitio y multipaís

Analítica y automatización aplicadas a la entrega

Inteligencia comercial con IA sobre datos operativos

Programas de datos e IA con caso de negocio, CAPEX y OPEX

AIOps y operación predictiva sobre infraestructura crítica

Lázaro Gómez Ontiveros

lazarogomez@hotmail.com

+52 55 7980 3050

linkedin.com/in/lazarogomezontiveros

Ciudad de México · disponible para viaje y reubicación

Todos los datos, cifras, escenarios y ejemplos de este documento son sintéticos y fueron construidos para ilustrar método. No contienen ni reproducen información de ningún cliente, proveedor o empleador, presente o pasado.